

UNIVERSIDAD DE COSTA RICA

ESCUELA DE CIENCIAS DE LA COMPUTACIÓN E INFORMÁTICA

PROGRAMA DE POSGRADO EN COMPUTACIÓN E INFORMÁTICA

PF-3311 AGENTES VIRTUALES INTELIGENTES

ENTREGABLE 1: PROPUESTA DE AGENTE E INVESTIGACIÓN

**EVALUACIÓN UX AUMENTADA CON IA PARA AGENTES VIRTUALES CORPORIZADOS:
COMPARACIÓN EXPLORATORIA ENTRE USUARIOS HUMANOS Y UN MODELO DE
LENGUAJE**

*AI-AUGMENTED UX EVALUATION FOR EMBODIED VIRTUAL AGENTS: AN EXPLORATORY COMPARISON
BETWEEN HUMAN USERS AND A LANGUAGE MODEL*

INVESTIGADOR:

DEIVERT GUILTRICHS CORDERO

PROFESOR:

ALEXANDER BARQUERO ELIZONDO

I CICLO, 2026

Tabla de contenido

1. Definición del problema	4
2. Revisión de literatura	5
2.1. Estrategia de búsqueda de literatura	5
2.2. Agentes conversacionales basados en modelos de lenguaje	6
2.3. Embodiment, antropomorfismo y experiencia de usuario	6
2.4. Agentes conversacionales en educación	7
2.5. Evaluación UX en sistemas de inteligencia artificial	8
2.6. Modelos de lenguaje como apoyo evaluativo	8
2.7. Riesgos metodológicos de comparar humanos y LLM	9
2.8. Consideraciones éticas y alcance del curso	9
2.9. Síntesis de la brecha de investigación	10
3. Preguntas de investigación	10
4. Objetivos del agente	10
4.1. Rol del agente	10
4.2. Comportamiento esperado	11
4.3. Contexto de uso	11
4.4. Usuario objetivo	11
5. Arquitectura técnica preliminar	11
5.1. Descripción general	11
5.2. Motor gráfico o plataforma de visualización	12
5.3. Solución de IA	12
5.4. Servicios de voz	12
5.5. Embodiment del agente	12
5.6. Entorno de despliegue	13
5.7. Diagrama conceptual de arquitectura	13
6. Protocolo preliminar de evaluación	14
6.1. Variable independiente	14
6.2. Variables dependientes	14
6.3. Instrumentos	14
6.4. Sesión paso a paso	15
6.5. Justificación de decisiones del protocolo	16

7. Estructura inicial del repositorio GitHub	18
7.1. Contenido del README.md.....	18
8. Referencias preliminares	19

1. Definición del problema

Los agentes conversacionales basados en modelos de lenguaje han adquirido una presencia creciente en contextos educativos, de asistencia y de interacción humano-computadora, debido a su capacidad para sostener diálogos naturales, responder preguntas, adaptar explicaciones y participar en intercambios de múltiples turnos [1], [14]. A diferencia de los chatbots tradicionales basados en reglas, estos sistemas pueden generar respuestas flexibles, contextuales y más cercanas al lenguaje humano, lo cual abre posibilidades para construir agentes virtuales que apoyen procesos de aprendizaje, expliquen conceptos académicos, respondan consultas frecuentes o acompañen tareas formativas [7], [16], [18].

Sin embargo, el valor de estos agentes no puede evaluarse únicamente desde la precisión textual de sus respuestas. Cuando una persona interactúa con un agente virtual, especialmente si este posee una representación visual o corporizada, la experiencia de usuario no depende solo de “qué responde” el sistema, sino también de “cómo se percibe” la interacción. Elementos como confianza, claridad, naturalidad, presencia, facilidad de uso, utilidad percibida, satisfacción, credibilidad y sensación de acompañamiento se vuelven relevantes para determinar si el agente resulta adecuado para un contexto académico [1], [2], [9]. La literatura reciente sobre agentes conversacionales basados en LLM muestra que el embodiment, la voz, el comportamiento antropomórfico, la personalidad y los principios de Theory of Mind pueden afectar la confianza, la presencia, la usabilidad y la experiencia de usuario percibida [1], [9].

Esta situación genera un reto metodológico importante: la evaluación de la experiencia de usuario en sistemas de IA no puede limitarse a aplicar instrumentos tradicionales de forma mecánica. Los sistemas basados en IA son dinámicos, generativos, contextuales y, en algunos casos, multimodales. Por ello, la evaluación UX debe considerar tanto métricas estandarizadas como dimensiones emergentes propias de la interacción humano-IA, tales como confianza, engagement emocional, riesgos éticos, comportamiento multimodal, credibilidad, control del usuario y percepción social del sistema [12], [14]. En este sentido, instrumentos como SUS, UEQ o NASA-TLX siguen siendo útiles, pero pueden resultar insuficientes si se utilizan de forma aislada para evaluar interfaces basadas en IA capaces de generar respuestas en tiempo real [10], [12], [16].

En el contexto educativo, esta necesidad de evaluación se vuelve aún más evidente. Los agentes conversacionales pueden apoyar procesos pedagógicos, responder preguntas, facilitar evaluaciones, reducir carga docente y ofrecer interacciones personalizadas [7], [16], [18]. No obstante, también pueden introducir riesgos asociados con respuestas incorrectas, dependencia excesiva, pérdida de conexión humana, problemas técnicos, privacidad de los datos o dificultad para interpretar adecuadamente sus salidas [4], [7], [16]. El estudio sobre Alvaluate, un agente conversacional pedagógico aumentado con LLM, muestra que este tipo de sistemas puede mejorar la consistencia procedimental y alcanzar una usabilidad aceptable, pero también identifica limitaciones como problemas técnicos y menor conexión personal frente a la interacción cara a cara [16].

A partir de este panorama, surge el problema central de esta propuesta: aunque existe literatura sobre agentes conversacionales basados en LLM, agentes educativos, embodiment

y evaluación UX, todavía se requiere explorar cómo puede utilizarse un modelo de lenguaje como evaluador complementario de la experiencia de usuario en un agente virtual corporizado. Esta evaluación no debe entenderse como sustitución de la percepción humana, ya que un LLM no experimenta UX. Más bien, debe concebirse como una valoración generada o simulada a partir de la interacción, útil para contrastar patrones, identificar coincidencias, observar diferencias y apoyar procesos tempranos de evaluación [12], [14], [15].

Esta distinción es metodológicamente relevante porque los LLM pueden producir respuestas estructuradas que se asemejan a respuestas humanas. Shahania et al. muestran que los LLM pueden superar mecanismos tradicionales de control en encuestas, como attention checks, Honeypot y CAPTCHA, e incluso imitar patrones de respuesta humanos en formatos estructurados [15]. Esto obliga a interpretar con cautela cualquier comparación entre respuestas humanas y respuestas generadas por IA.

Por tanto, este proyecto propone desarrollar y evaluar, de manera exploratoria y controlada, un agente virtual corporizado orientado a brindar apoyo académico básico a estudiantes universitarios. La evaluación comparará dos fuentes de valoración: por un lado, la experiencia reportada por usuarios humanos después de interactuar con el agente; por otro, una evaluación generada por un modelo de lenguaje a partir del mismo escenario de interacción. El objetivo no es demostrar que el modelo de lenguaje pueda reemplazar a los usuarios, sino analizar si puede funcionar como herramienta complementaria en fases tempranas de evaluación UX de agentes virtuales inteligentes.

La brecha específica que atiende este trabajo se ubica en la intersección entre agentes virtuales corporizados, evaluación UX, educación superior y uso de modelos de lenguaje como apoyo evaluativo. En este sentido, la investigación busca aportar evidencia inicial sobre el grado de concordancia entre evaluaciones humanas y evaluaciones generadas por LLM, así como identificar consideraciones metodológicas para incorporar IA en procesos exploratorios de evaluación UX sin desplazar la centralidad de la experiencia humana.

2. Revisión de literatura

2.1. Estrategia de búsqueda de literatura

Para construir la revisión de literatura se consultaron fuentes académicas provenientes de ACM y Springer, seleccionadas a partir de una cadena de búsqueda orientada a recuperar estudios sobre agentes virtuales, experiencia de usuario, evaluación humana, modelos de lenguaje y contexto educativo. La cadena utilizada fue la siguiente:

("embodied conversational agent" OR "embodied virtual agent" OR "virtual agent" OR "conversational agent") AND ("user experience" OR UX OR usability OR "user evaluation" OR "human evaluation") AND ("large language model" OR LLM OR "LLM-as-a-judge" OR "AI evaluation")
--

AND (education OR learning OR "higher education" OR "academic support" OR tutoring)
--

A partir de esta estrategia, las fuentes se organizaron en seis ejes principales: agentes conversacionales basados en LLM, agentes virtuales corporizados y embodiment, agentes conversacionales en educación, evaluación UX en sistemas de IA / LLM como apoyo evaluativo y consideraciones metodológicas o éticas asociadas a estudios con participantes humanos.

2.2. Agentes conversacionales basados en modelos de lenguaje

Los agentes conversacionales basados en modelos de lenguaje representan una evolución significativa respecto a los sistemas conversacionales tradicionales. Estos agentes pueden sostener interacciones más naturales, procesar lenguaje de forma contextual y generar respuestas adaptadas al flujo de la conversación [1], [3], [14]. En escenarios de múltiples turnos, los LLM permiten que el agente mantenga continuidad, retome información previa y responda de manera más flexible a las necesidades del usuario [14].

Guan et al. explican que un agente conversacional basado en LLM no es simplemente un modelo que responde a un prompt aislado, sino un sistema que puede integrar memoria, planificación y uso de herramientas para sostener una interacción más compleja [14]. Esta caracterización es relevante para el proyecto porque el agente propuesto no se concibe como una interfaz estática, sino como un interlocutor académico capaz de explicar conceptos, responder preguntas y adaptar sus respuestas al usuario dentro de una sesión controlada.

A la vez, la literatura advierte que estas capacidades introducen nuevos desafíos. Los sistemas agentic pueden manejar tareas complejas, pero también pueden dificultar que los usuarios comprendan los límites reales del sistema, sus fuentes de información, sus capacidades y sus posibles errores [4]. Por ello, el diseño del agente debe comunicar claramente su alcance: brindar apoyo académico básico, no sustituir al docente ni actuar como fuente única de conocimiento.

2.3. Embodiment, antropomorfismo y experiencia de usuario

La literatura sobre agentes virtuales corporizados muestra que la experiencia de usuario no depende únicamente de la respuesta verbal generada por el sistema. El grado de embodiment, la voz, la expresión visual, los gestos, el movimiento corporal, el comportamiento social y la personalidad del agente pueden influir en la manera en que los usuarios interpretan la interacción [1], [9], [10].

Schlesener et al. diferencian varios niveles de forma antropomórfica: chatbot textual, chatbot con texto a voz y embodied conversational agent. El ECA representa el nivel más alto de embodiment porque simula interacciones cara a cara mediante una combinación de comportamientos verbales y no verbales, como lip-sync, expresiones faciales, gestos, backchanneling, movimientos corporales y movimiento ocular [1]. Esta caracterización permite distinguir un agente corporizado de un chatbot textual simple.

El mismo estudio indica que el embodiment y los comportamientos basados en Theory of Mind pueden afectar percepciones como confianza, antropomorfismo, presencia, usabilidad y experiencia de usuario [1]. Para esta propuesta, esto justifica que el prototipo no sea evaluado únicamente como una interfaz funcional, sino como una experiencia de interacción con una entidad visual y conversacional.

La personalidad también aparece como una dimensión relevante. Byeon et al. encontraron que la personalidad percibida de un chatbot puede afectar la credibilidad de la información en sistemas de búsqueda conversacional basados en LLM [2]. En particular, los rasgos de conscientiousness y agreeableness se asociaron con mayor credibilidad, mientras que extraversión y neuroticism pueden disminuirla [2]. De forma complementaria, Han et al. muestran que los LLM pueden generar comportamientos verbales y no verbales alineados con rasgos de personalidad, y que los usuarios pueden reconocer dichos rasgos en agentes virtuales [9].

Estos hallazgos refuerzan que el diseño del agente no debe limitarse al contenido de las respuestas. También deben considerarse la forma en que el agente se presenta, el tono conversacional, la naturalidad, la credibilidad y la consistencia del comportamiento.

2.4. Agentes conversacionales en educación

En educación, los agentes conversacionales se han utilizado para responder consultas, apoyar tareas, ofrecer retroalimentación, facilitar evaluaciones y personalizar la interacción con estudiantes [7], [16], [18], [19]. La literatura reciente muestra que estos agentes pueden reducir carga docente, automatizar tareas repetitivas, ofrecer apoyo académico inmediato y facilitar experiencias de aprendizaje más adaptativas [16], [18].

Sedrakyan et al. destacan que los chatbots educativos pueden apoyar la entrega de información sobre contenidos, promover aprendizaje colaborativo, facilitar práctica mediante preguntas y respuestas, brindar soporte personalizado y apoyar procesos de reflexión [7]. Sin embargo, también advierten que los diseños actuales suelen carecer de fundamentos sólidos en ciencias del aprendizaje, lo cual puede limitar su efectividad pedagógica [7].

La revisión sobre integración de chatbots con LMS también destaca el potencial de los chatbots educativos para ofrecer engagement en tiempo real, retroalimentación inmediata, evaluación automatizada y personalización. No obstante, Wong y Chan identifican que la personalización y la evaluación empírica de percepciones de estudiantes y docentes siguen siendo áreas que requieren mayor investigación [18].

El estudio sobre Alvaluate es especialmente relevante porque presenta un agente conversacional pedagógico aumentado con LLM, diseñado para apoyar evaluaciones basadas en desempeño. El sistema fue evaluado mediante un diseño mixto con docentes y estudiantes, utilizando calificaciones, cuestionarios SUS y respuestas abiertas. Los resultados reportan una usabilidad aceptable y ventajas asociadas con preguntas más estructuradas, consistencia procedimental y reportes emocionales, aunque también se identifican limitaciones técnicas y menor conexión personal frente a la interacción cara a cara [16].

Este antecedente respalda la pertinencia de construir un agente educativo de alcance controlado. Sin embargo, también evidencia que estos sistemas deben evaluarse desde dimensiones humanas y pedagógicas, no solo desde su funcionalidad técnica. En el caso de este proyecto, el agente se propone como apoyo académico básico para explicar conceptos introductorios, no como sustituto del docente ni como sistema formal de evaluación del aprendizaje.

2.5. Evaluación UX en sistemas de inteligencia artificial

La evaluación UX de sistemas de IA enfrenta desafíos distintos a los de sistemas tradicionales. Los agentes basados en LLM generan respuestas dinámicas, pueden variar entre interacciones, producen resultados no siempre previsibles y generan percepciones sociales en los usuarios [12], [14]. Por eso, evaluar únicamente el cumplimiento funcional de la tarea resulta insuficiente.

Zheng et al. plantean que la rápida integración de IA en sistemas interactivos representa un reto creciente para la evaluación UX. Aunque instrumentos como SUS, UEQ y NASA-TLX son ampliamente utilizados, los autores señalan que estos marcos pueden resultar insuficientes para capturar la complejidad de las interacciones humano-IA, especialmente cuando intervienen confianza, engagement emocional, consideraciones éticas y comportamientos multimodales [12].

En esa misma línea, la evaluación UX debe entenderse como un proceso multidimensional. No basta con medir si el sistema funciona, sino que se deben considerar percepciones, actitudes, contexto de uso, carga cognitiva, claridad, utilidad, confianza y satisfacción [6], [10], [12]. Para esta investigación, esto justifica que las variables dependientes incluyan usabilidad percibida, claridad de la interacción, utilidad percibida, satisfacción general, confianza y naturalidad del agente.

La evaluación de sistemas conversacionales también puede combinar métricas subjetivas y objetivas. Por ejemplo, el estudio de EventChat utilizó métricas subjetivas de percepción de usuario junto con métricas objetivas como latencia, uso de tokens y registros de interacción [6]. Esta aproximación es útil porque permite comprender tanto la experiencia percibida como el comportamiento técnico del sistema. Para el presente proyecto, aunque el alcance del curso sea más reducido, se puede mantener esta lógica mediante cuestionarios breves, preguntas abiertas y registro controlado de la sesión.

2.6. Modelos de lenguaje como apoyo evaluativo

Una línea emergente de investigación explora el uso de LLM para apoyar procesos de evaluación, diseño de métricas y planificación de estudios UX. EvAlignUX, por ejemplo, es un sistema basado en LLM que ayuda a investigadores HCI a explorar métricas de evaluación UX, resultados esperados y riesgos asociados con proyectos de interacción humano-IA [12]. En una evaluación con investigadores HCI, el sistema mejoró la claridad, concreción y confianza de los planes de evaluación revisados, y ayudó a justificar métricas, autoevaluar planes y considerar riesgos [12].

Este antecedente es importante porque respalda el uso de LLM como herramienta de apoyo a la evaluación, no solo como motor conversacional del agente. En el presente proyecto, el LLM no se utilizará únicamente para generar respuestas del agente, sino también como evaluador complementario que analiza la interacción y responde el mismo instrumento aplicado a los usuarios humanos.

También existen antecedentes sobre agentes virtuales y cuestionarios. Yun et al. muestran que los LLM pueden generar variantes de preguntas para entrevistas administradas por agentes virtuales, manteniendo propiedades psicométricas y reduciendo la repetitividad percibida por los participantes [8]. Esto evidencia que los LLM pueden intervenir en procesos estructurados de medición y evaluación, siempre que exista revisión humana y cuidado metodológico.

No obstante, esta función debe formularse cuidadosamente. El LLM no “vive” ni “siente” la experiencia de usuario. Lo que produce es una evaluación generada a partir de la información disponible, posiblemente útil para identificar patrones o anticipar problemas, pero no equivalente a la percepción humana. Esta precisión evita caer en una interpretación antropomórfica excesiva del modelo.

2.7. Riesgos metodológicos de comparar humanos y LLM

La comparación entre respuestas humanas y respuestas generadas por un LLM requiere cautela. La literatura reciente muestra que los modelos de lenguaje pueden producir respuestas estructuradas que imitan patrones humanos. Shahania et al. demostraron que los LLM pueden superar controles tradicionales de calidad en encuestas, como Honeypot, attention checks y CAPTCHA, e incluso generar patrones de respuesta similares a los humanos en ciertos formatos estructurados [15].

Este hallazgo es directamente relevante para el proyecto. Si un LLM responde un cuestionario UX de forma similar a un usuario humano, esto no significa que haya experimentado la interacción. Significa que pudo generar una valoración plausible a partir de los datos disponibles. Por ello, la comparación propuesta debe analizar concordancias y diferencias, pero sin asumir equivalencia entre experiencia humana y respuesta generada por IA.

Desde esta perspectiva, el LLM debe ser tratado como un evaluador complementario o simulador evaluativo. Su utilidad potencial está en apoyar fases tempranas de diseño, sugerir posibles problemas, contrastar resultados o ayudar a interpretar dimensiones UX. Su límite está en que no sustituye la experiencia situada, subjetiva y contextual de las personas usuarias.

2.8. Consideraciones éticas y alcance del curso

Aunque este proyecto se desarrolla en el marco de un curso y no como una investigación doctoral completa, involucra interacción con participantes humanos y recolección de datos de percepción. Por tanto, deben considerarse principios básicos de ética en investigación HCI/IA: participación voluntaria, explicación clara del propósito, consentimiento informado, minimización de datos, confidencialidad y uso académico de la información [20].

Dittrich y Reichenbach señalan que los estudios en HCI e IA que recolectan datos de participantes humanos deben considerar el bienestar de los participantes, la privacidad, la

confidencialidad, la autonomía y el consentimiento informado, incluso cuando el estudio no sea médico [20]. Esto implica que el protocolo del curso debe evitar recopilar datos sensibles innecesarios, explicar que el agente es un prototipo académico y aclarar que los resultados serán utilizados únicamente con fines educativos y exploratorios.

El alcance debe mantenerse controlado. La muestra puede ser pequeña, la sesión breve y el análisis exploratorio. El objetivo no es generalizar resultados ni validar definitivamente un marco de evaluación, sino construir una primera evidencia comparativa entre evaluaciones humanas y evaluaciones generadas por LLM en un escenario académico acotado.

2.9. Síntesis de la brecha de investigación

La literatura revisada muestra avances en agentes conversacionales basados en LLM, agentes corporizados, agentes educativos, evaluación UX y herramientas de apoyo evaluativo con modelos de lenguaje [1], [7], [12], [14], [16], [18]. Sin embargo, todavía se identifica una brecha en la comparación directa entre evaluaciones UX realizadas por usuarios humanos y evaluaciones UX generadas por un LLM sobre una misma interacción con un agente virtual corporizado en contexto educativo.

La contribución de este proyecto será exploratoria y metodológica. Se busca analizar si un modelo de lenguaje puede actuar como evaluador complementario en fases tempranas de evaluación UX, identificando concordancias, diferencias y límites frente a la evaluación humana. Esta contribución es pertinente porque permite estudiar el potencial de la IA como apoyo al diseño y evaluación de agentes virtuales, manteniendo la evaluación humana como referencia central.

3. Preguntas de investigación

RQ1. ¿Qué grado de concordancia existe entre las puntuaciones obtenidas por usuarios humanos y las generadas por un modelo de lenguaje, analizadas por dimensiones del instrumento UX?

RQ2. ¿En qué medida las puntuaciones generadas por el modelo de lenguaje evaluador concuerdan con las puntuaciones reportadas por usuarios humanos, considerando como referencia exploratoria mínima un ICC ≥ 0.70 y contrastando si se aproximan o superan el umbral de ICC ≥ 0.75 asociado con buena confiabilidad?

RQ3. ¿Qué limitaciones, riesgos y consideraciones deben tomarse en cuenta al incorporar un modelo de lenguaje como evaluador complementario de UX en agentes virtuales corporizados?

4. Objetivos del agente

4.1. Rol del agente

El agente virtual corporizado cumplirá el rol de asistente académico básico para estudiantes universitarios de grado. Su función principal será explicar conceptos introductorios de bases

de datos de manera clara, breve y comprensible. El agente deberá responder preguntas guiadas, ofrecer ejemplos cotidianos y confirmar la comprensión del usuario.

No se pretende que el agente sustituya a la persona docente ni que cubra todo el contenido de un curso de bases de datos. Su alcance se limitará a una interacción controlada, orientada a evaluar la experiencia de usuario generada por el agente.

4.2. Comportamiento esperado

El agente deberá comportarse de manera:

- Clara: utilizar explicaciones simples y evitar tecnicismos innecesarios.
- Breve: responder de forma concreta para no sobrecargar al estudiante.
- Académicamente correcta: mantener precisión conceptual en temas básicos de bases de datos.
- Amigable: emplear un tono cercano, respetuoso y de apoyo.
- Controlada: redirigir la conversación cuando el usuario formule preguntas fuera del alcance del prototipo.

4.3. Contexto de uso

El contexto de uso será una sesión breve de interacción académica en la que el usuario solicita apoyo para comprender conceptos básicos de bases de datos. El escenario principal consistirá en que un estudiante pregunta al agente sobre diseño de bases de datos, solicita un ejemplo cotidiano y confirma su comprensión.

4.4. Usuario objetivo

El usuario objetivo será un estudiante universitario de grado o una persona con experiencia básica en herramientas digitales. No se requiere que el usuario tenga conocimientos avanzados en bases de datos, ya que el agente está orientado a explicar conceptos introductorios.

Para efectos de la evaluación del curso, se trabajará con una muestra pequeña de aproximadamente 15 a 20 participantes o, si el alcance ético lo requiere, con evaluación experta o piloto controlado. La participación será breve, voluntaria y orientada a fines académicos.

5. Arquitectura técnica preliminar

5.1. Descripción general

La arquitectura técnica del prototipo se organizará en cinco componentes principales:

1. Interfaz de usuario y visualización del agente.
2. Motor de interacción conversacional.

3. Modelo de lenguaje para generación de respuestas.
4. Módulo de evaluación UX aumentada con IA.
5. Registro controlado de interacciones para análisis posterior.

5.2. Motor gráfico o plataforma de visualización

Se propone utilizar Unity como motor principal para representar el agente virtual corporizado. Unity permite construir una interfaz visual controlada, integrar avatares 3D o semi-3D, manejar animaciones básicas y desplegar el prototipo en PC. Para el alcance del curso, no es indispensable desarrollar un avatar hiperrealista; basta con una representación visual funcional que permita al usuario percibir que interactúa con un agente corporizado.

Como alternativa de alcance mínimo viable, se podrá utilizar una interfaz web con avatar animado básico si la integración en Unity excede el tiempo disponible. Esta alternativa mantendría el objetivo de evaluación UX, aunque con menor complejidad visual.

5.3. Solución de IA

El prototipo utilizará dos modelos de lenguaje con funciones diferenciadas. El primer modelo, denominado LLM-A, será utilizado como motor conversacional del agente virtual y generará las respuestas académicas dirigidas al usuario.

El segundo modelo, denominado LLM-B, será utilizado como evaluador complementario de la experiencia de usuario. LLM-B recibirá la transcripción o descripción controlada de la interacción y completará el mismo instrumento UX aplicado a los usuarios humanos. Esta separación busca reducir el riesgo de circularidad metodológica, evitando que el mismo modelo que genera la interacción evalúe posteriormente sus propios patrones de respuesta.

5.4. Servicios de voz

La integración de voz se considera una mejora deseable, pero no un requisito crítico para el primer prototipo. Si el tiempo lo permite, se podrá incorporar texto a voz mediante servicios como Azure Speech, Google Text-to-Speech o ElevenLabs. Para reconocimiento de voz, se podría utilizar una solución de Speech-to-Text o entrada textual como alternativa.

La modalidad mínima viable será entrada por texto y salida por texto o voz. Esta decisión permite asegurar que la evaluación pueda realizarse incluso si la integración completa de voz presenta problemas técnicos.

5.5. Embodiment del agente


El agente tendrá una representación visual mediante avatar 3D, semi-3D o personaje animado. Idealmente, el avatar incluirá animaciones básicas de habla, gestos simples o expresiones faciales. El uso de blendshapes para lip-sync se considera deseable, pero no obligatorio para el alcance del curso.

El objetivo del embodiment no será demostrar realismo gráfico avanzado, sino ofrecer presencia visual suficiente para que la persona usuaria perciba una interacción con un agente corporizado y no únicamente con un chatbot textual.

5.6. Entorno de despliegue

El entorno de despliegue previsto será una computadora personal, ya sea mediante una aplicación local desarrollada en Unity o mediante una interfaz web ejecutada en navegador. Esta decisión reduce la complejidad técnica y facilita la aplicación de pruebas piloto en un contexto académico.

5.7. Diagrama conceptual de arquitectura



6. Protocolo preliminar de evaluación

Aunque este entregable se centra en la propuesta del agente y la investigación, se incluye un protocolo preliminar para mostrar la viabilidad de evaluación en entregas posteriores.

6.1. Variable independiente

La variable independiente experimental será el tipo de interfaz del sistema. Se compararán dos condiciones: Condición A, agente virtual corporizado con avatar visual básico; y Condición B, interfaz conversacional textual plana sin avatar ni animación. De forma complementaria, el estudio incluirá una comparación metodológica entre la evaluación UX reportada por usuarios humanos y la evaluación generada por un segundo modelo de lenguaje, LLM-B, a partir de las transcripciones de interacción.

No se manipulará el contenido académico ni el comportamiento conversacional de fondo del agente. La comparación se limitará a la modalidad de interfaz: agente corporizado con avatar visual básico frente a chat textual plano.

6.2. Variables dependientes

Las variables dependientes serán las dimensiones de experiencia de usuario obtenidas mediante el instrumento seleccionado. Se medirán principalmente:

- Usabilidad percibida.
- Claridad de la interacción.
- Facilidad de comprensión.
- Utilidad percibida.
- Satisfacción general.
- Percepción de naturalidad del agente.
- Confianza.
- Credibilidad.
- Antropomorfismo.
- Simpatía.
- Inteligencia percibida.
- Seguridad percibida.

También se podrá registrar el tiempo aproximado de interacción y observaciones cualitativas breves sobre problemas o aspectos positivos detectados durante la prueba.

6.3. Instrumentos

Se utilizará UEQ-S [21] como instrumento principal para medir experiencia de usuario. De forma complementaria, se utilizarán dimensiones seleccionadas de la escala Godspeed [22]

para evaluar antropomorfismo, simpatía, inteligencia y seguridad percibidas. Además, se incorporará una pregunta abierta post-interacción. Para comparar las puntuaciones humanas con las puntuaciones generadas por LLM-B, se utilizará el coeficiente de correlación intraclass, ICC [23], como métrica estadística de concordancia.

6.4. Sesión paso a paso

1. Recepción e introducción: se recibe al participante y se le explica que participará en una prueba académica de un prototipo de agente virtual orientado a explicar conceptos básicos de bases de datos. Se aclara que la sesión tiene fines educativos y exploratorios, que no se evaluará su conocimiento académico y que puede retirarse en cualquier momento sin consecuencia alguna.
2. Consentimiento e identificación anónima: antes de iniciar la interacción, el participante acepta el consentimiento informado. Luego, se le asigna un identificador anónimo de participante. No se recopilarán datos sensibles, credenciales, documentos personales, capturas de pantalla ni información privada. Los registros de la sesión se asociarán únicamente con el identificador anónimo.
3. Asignación de condición experimental: el participante será asignado a una de dos condiciones. En la Condición A interactuará con un agente virtual corporizado con avatar visual básico. En la Condición B interactuará con una interfaz conversacional textual plana, sin avatar ni animación. Ambas condiciones utilizarán el mismo dominio temático, el mismo guion de interacción, el mismo modelo conversacional LLM-A y las mismas restricciones de respuesta.
4. Instrucciones iniciales de la tarea: se indicará al participante que debe interactuar con el sistema siguiendo una tarea guiada. La tarea consistirá en solicitar una explicación sencilla sobre diseño de bases de datos, pedir un ejemplo cotidiano, preguntar por la diferencia entre clave primaria y clave foránea, y confirmar si la explicación fue clara o solicitar una aclaración. Las instrucciones se presentarán de manera neutral, sin indicar que una condición es superior a la otra.
5. Interacción con el agente: el participante interactuará con el sistema durante una sesión breve, aproximada de 10 a 15 minutos. El agente será operado por el modelo LLM-A, configurado para responder de forma breve, clara, pedagógica y limitada al dominio de conceptos introductorios de bases de datos.
6. Registro controlado de la sesión: al finalizar la interacción, se conservará una transcripción o descripción textual controlada de la sesión. Este registro incluirá únicamente el identificador anónimo, la condición asignada, la duración aproximada, el número de intervenciones, la finalización o no de la tarea y el contenido conversacional necesario para el análisis posterior.
7. Aplicación de instrumentos UX al participante: después de la interacción, el participante completará el instrumento UEQ-S como medición principal de experiencia de usuario. De forma complementaria, responderá dimensiones seleccionadas de la escala Godspeed para valorar antropomorfismo, simpatía, inteligencia y seguridad percibidas. También responderá una pregunta abierta breve sobre aspectos positivos, dificultades o percepciones generales de la interacción.

8. Evaluación complementaria con IA: la transcripción o descripción controlada de la sesión será entregada a un segundo modelo de lenguaje, LLM-B, diferente del modelo utilizado para operar el agente. LLM-B completará el mismo instrumento UX aplicado a los usuarios humanos, a partir de la información disponible sobre la interacción y la condición experimental asignada.
9. Comparación y análisis: finalmente, se compararán las puntuaciones reportadas por usuarios humanos con las puntuaciones generadas por LLM-B. El análisis incluirá estadística descriptiva por dimensión UX y el cálculo del coeficiente de correlación intraclass, ICC, como métrica de concordancia. Se utilizará $ICC \geq 0.70$ como referencia exploratoria mínima y se contrastará si los resultados se aproximan o superan $ICC \geq 0.75$, umbral asociado con buena confiabilidad.

6.5. Justificación de decisiones del protocolo

Decisión del protocolo	Justificación
Comparar dos condiciones de interfaz	La comparación entre agente virtual corporizado y chat textual plano permite aislar el posible efecto del embodiment visual sobre la experiencia de usuario, manteniendo constante el contenido académico, el guion de tarea y el modelo conversacional.
Mantener el mismo dominio temático en ambas condiciones	Usar el mismo tema de bases de datos en ambas condiciones reduce variaciones externas y permite que las diferencias observadas se relacionen principalmente con la modalidad de interfaz.
Utilizar un guion base de interacción	El guion aumenta la consistencia entre sesiones y permite que las interacciones humanas y las evaluaciones generadas por LLM-B sean más comparables.
Usar LLM-A como motor conversacional	Separar el modelo que opera el agente permite definir claramente la función conversacional del sistema y limitarlo a respuestas breves, claras y pedagógicas sobre conceptos introductorios de bases de datos.
Usar LLM-B como evaluador complementario	Utilizar un segundo modelo para evaluar la interacción reduce el riesgo de circularidad metodológica, evitando que el mismo modelo que genera las respuestas evalúe posteriormente sus propios patrones de interacción.
Comparar evaluación humana vs evaluación generada por LLM-B	Esta comparación responde directamente al propósito del proyecto: explorar si un modelo de lenguaje puede funcionar como evaluador complementario de experiencia de usuario en fases tempranas de diseño.
Utilizar UEQ-S como instrumento principal	UEQ-S es un instrumento breve y adecuado para evaluar experiencia de usuario en contextos donde el tiempo de


	aplicación es limitado. Permite obtener puntuaciones comparables sobre dimensiones pragmáticas y hedónicas de la experiencia.
Utilizar dimensiones seleccionadas de Godspeed	Godspeed permite evaluar percepciones sociales relevantes para agentes virtuales, como antropomorfismo, simpatía, inteligencia percibida y seguridad percibida. Estas dimensiones son coherentes con la comparación entre una interfaz corporizada y una textual plana.
Incluir una pregunta abierta post-interacción	La pregunta abierta permite recoger comentarios cualitativos que pueden ayudar a interpretar diferencias entre condiciones, discrepancias entre humanos y LLM-B, o aspectos no capturados por los cuestionarios cerrados.
Registrar métricas operativas simples	La duración aproximada, finalización de tarea y número de intervenciones ayudan a contextualizar la experiencia sin convertir el estudio en una evaluación técnica compleja.
Usar ICC como métrica de concordancia	El coeficiente de correlación intraclase permite estimar el nivel de acuerdo entre fuentes de evaluación que valoran el mismo objeto. En este caso, se utilizará para comparar las puntuaciones humanas con las generadas por LLM-B.
Definir ICC ≥ 0.70 como referencia exploratoria mínima	Este umbral permite establecer una meta cuantitativa inicial para discutir la concordancia entre humanos y LLM-B, sin interpretarla como validación definitiva del modelo evaluador.
Reportar también ICC ≥ 0.75	Reportar si el resultado alcanza o supera 0.75 permite contrastar los hallazgos con una referencia más exigente asociada con buena confiabilidad.
Utilizar identificadores anónimos	El uso de ID anónimo protege la identidad del participante y permite vincular condición, transcripción, respuestas UX y métricas operativas sin recopilar datos personales innecesarios.
Mantener la sesión entre 10 y 15 minutos	Esta duración reduce la carga para el participante y hace viable la ejecución dentro del alcance del curso.
No medir variables multimodales avanzadas	El prototipo se enfocará en una interacción textual con representación visual básica. Por tanto, no se medirán directamente tono de voz, gestos complejos, microexpresiones, movimiento ocular ni fluidez de animación.
Mantener el análisis como exploratorio	El tamaño de muestra y el alcance del curso no permiten generalizar resultados, pero sí identificar tendencias iniciales,

	diferencias entre condiciones y limitaciones metodológicas del uso de LLM como evaluador complementario.
--	--

Como aclaración metodológica, el estudio contempla dos niveles de comparación. El primer nivel corresponde a una comparación experimental entre dos condiciones de interfaz: agente virtual corporizado y chat textual plano. Esta comparación busca aislar el efecto del embodiment visual. El segundo nivel corresponde a una comparación metodológica entre las evaluaciones UX reportadas por usuarios humanos y las evaluaciones generadas por LLM-B. Esta segunda comparación no constituye una condición experimental del sistema, sino una estrategia para analizar el potencial del LLM como evaluador complementario.

7. Estructura inicial del repositorio GitHub

El repositorio del proyecto se encuentra en la dirección: <https://github.com/deivert-guiltrichs/ai-ux-embodied-agent-evaluation> ; y se organizará de la siguiente manera:



7.1. Contenido del README.md

Evaluación UX aumentada con IA para agentes virtuales corporizados Este repositorio contiene la propuesta, documentación y estructura inicial del proyecto individual del curso PF-3311 Agentes Virtuales Inteligentes. ## Descripción

El proyecto propone construir y evaluar un agente virtual corporizado orientado a explicar conceptos básicos de bases de datos a estudiantes universitarios. La investigación compara la evaluación de experiencia de usuario realizada por usuarios humanos con una evaluación generada por un modelo de lenguaje a partir del mismo escenario de interacción.

Objetivo general

Explorar la utilidad de un modelo de lenguaje como evaluador complementario de experiencia de usuario en un agente virtual corporizado académico.

Estructura del repositorio

- `/docs` : documentos formales de entrega.
- `/prototype` : estructura inicial del prototipo del agente.
- `/evaluation` : instrumentos y protocolo de evaluación.
- `/prompts` : prompts preliminares para el agente y para la evaluación con IA.

Advertencia de seguridad

No se incluyen API keys, credenciales ni datos personales en el repositorio.

8. Referencias preliminares

- [1] E. A. Schlesener, M. Ziolkowski, S.-K. Wong, B. Westmoreland, and S. V. Babu, “Am I Understood?: How the Interplay between Embodiment and Theory of Mind Behavior Affects LLM-Based Conversational Agents on Perceived Trust, Anthropomorphism, Presence, Usability, and User Experience,” *ACM Transactions on Interactive Intelligent Systems*, vol. 16, no. 2, Article 11, 2026.
- [2] H. Byeon, U. Oh, and G. Hsieh, “Understanding the Effects of Conversational Agent Personality on the Credibility of LLM-Based Conversational Search,” in *Proceedings of the 2026 ACM SIGIR Conference on Human Information Interaction and Retrieval*, 2026.
- [3] J. Zhang et al., “LLM-Powered Agents for Web Interaction and Social Simulation,” ACM, 2025.
- [4] H. Candello, M. Brachman, G. Trovato, and collaborators, “Designing Conversational Agent(ic) Systems,” in *Proceedings of the ACM Conference on Conversational User Interfaces*, 2025.
- [5] S. Pal et al., “SPICA: Scalable and Personalized Conversational Agent Framework for AAC Users,” in *Proceedings of the ACM International Conference on Intelligent User Interfaces*, 2026.
- [6] EventChat authors, “EventChat: Field Evaluation of an LLM-Driven Conversational Recommender System,” *ACM Transactions on Recommender Systems*, 2025.
- [7] G. Sedrakyan, S. Borsci, S. van den Berg, J. van Hillegersberg, and B. Veldkamp, “Design Implications for Next Generation Chatbots with Education 5.0,” in *New Technology in Education and Training*, Springer, 2024.
- [8] H. S. Yun, M. Arjmand, P. Sherlock, M. K. Paasche-Orlow, J. W. Griffith, and T. Bickmore, “Keeping Users Engaged During Repeated Interviews by a Virtual Agent: Using Large Language

Models to Reliably Diversify Questions,” in *Proceedings of the ACM International Conference on Intelligent Virtual Agents*, 2024.

[9] B. Han, D. Kwon, S. Lin, K. Shrestha, and J. Gratch, “Can LLMs Generate Behaviors for Embodied Virtual Agents Based on Personality Traits?,” in *Proceedings of the ACM International Conference on Intelligent Virtual Agents*, 2025.

[10] S. Rasouli, M. Ghafurian, and K. Dautenhahn, “Co-Design and User Evaluation of a Robotic Mental Well-Being Coach to Support University Students’ Public Speaking Anxiety,” *ACM Transactions on Computer-Human Interaction*, vol. 32, no. 3, Article 24, 2025.

[11] Liu et al., “Adaptive, Personalized LLM-Based Agents for Mitigating Cognitive Overload in Web-Based Tasks,” in *Proceedings of the CHI Conference on Human Factors in Computing Systems*, 2026.

[12] Q. Zheng et al., “EvAlignUX: Advancing UX Evaluation through LLM-Supported Metrics Exploration,” in *Proceedings of the CHI Conference on Human Factors in Computing Systems*, 2025.

[13] A. Mohamed, M. Assi, and M. Guizani, “The Impact of LLM-Assistants on Software Developer Productivity: A Systematic Review and Mapping Study,” *ACM Transactions on Software Engineering and Methodology*, 2026.

[14] S. Guan, J. Wang, J. Bian, B. Zhu, J.-G. Lou, and H. Xiong, “Evaluating LLM-Based Agents for Multi-Turn Conversations: A Survey,” *ACM Transactions on Intelligent Systems and Technology*, vol. 17, no. 4, Article 85, 2026.

[15] S. Shahania, M. Spiliopoulou, and D. Broneske, “Gotta Catch ’Em All... Or Not?: How LLMs Bypass Traditional Checks & Mimic Human Response Behavior in Web Surveys,” in *Proceedings of the Collective Intelligence Conference*, ACM, 2025.

[16] H. Yusuf, A. Money, and D. Daylamani-Zad, “Towards Reducing Teacher Burden in Performance-Based Assessments Using Alvaluate: An Emotionally Intelligent LLM-Augmented Pedagogical AI Conversational Agent,” *Education and Information Technologies*, Springer, 2025.

[17] J. B. Ilagan, W. S. Yu, S. M. See, and S. Rayco, “A Virtual Support Agent for University Students Powered by a Large Language Model: Conversational User Experience Design Considerations,” in *Artificial Intelligence in HCI*, Springer, 2025.

[18] A. K. L. Wong and L. L. Chan, “Integrating Chatbots with Learning Management Systems for Personalized Learning: A Comprehensive Review and Framework Proposal—the CLIF,” *Discover Education*, Springer, 2025.

[19] P. Mithun, E. Noriega-Atala, N. Merchant, and E. Skidmore, “A Gateway for Egalitarian Access to LLM Based Resources,” in *Artificial Intelligence in Education*, Springer, 2025.

[20] P. B. Dittrich and A. Reichenbach, “Research Ethics for Data Collection from Human Participants: Case Study and Recommendations,” in *Artificial Intelligence in HCI*, Springer, 2025.

- [21] M. Schrepp, A. Hinderks, and J. Thomaschewski, "Design and Evaluation of a Short Version of the User Experience Questionnaire (UEQ-S)," *International Journal of Interactive Multimedia and Artificial Intelligence*, vol. 4, no. 6, pp. 103–108, 2017.
- [22] C. Bartneck, D. Kulić, E. Croft, and S. Zoghbi, "Measurement Instruments for the Anthropomorphism, Animacy, Likeability, Perceived Intelligence, and Perceived Safety of Robots," *International Journal of Social Robotics*, vol. 1, no. 1, pp. 71–81, 2009.
- [23] T. K. Koo and M. Y. Li, "A Guideline of Selecting and Reporting Intraclass Correlation Coefficients for Reliability Research," *Journal of Chiropractic Medicine*, vol. 15, no. 2, pp. 155–163, 2016.