

UNIVERSIDAD DE COSTA RICA

ESCUELA DE CIENCIAS DE LA COMPUTACIÓN E INFORMÁTICA

PROGRAMA DE POSGRADO EN COMPUTACIÓN E INFORMÁTICA

PF-3311 AGENTES VIRTUALES INTELIGENTES

ENTREGABLE 2: AVANCE DE AGENTE E INVESTIGACIÓN

**EVALUACIÓN UX AUMENTADA CON IA PARA AGENTES VIRTUALES CORPORIZADOS:
COMPARACIÓN EXPLORATORIA ENTRE USUARIOS HUMANOS Y UN MODELO DE
LENGUAJE**

*AI-AUGMENTED UX EVALUATION FOR EMBODIED VIRTUAL AGENTS: AN EXPLORATORY COMPARISON
BETWEEN HUMAN USERS AND A LANGUAGE MODEL*

INVESTIGADOR:

DEIVERT GUILTRICHS CORDERO

PROFESOR:

ALEXANDER BARQUERO ELIZONDO

I CICLO, 2026

Tabla de contenido

1. Introducción	5
2. Resumen de cambios desde el Entregable 1	5
3. Estado actual del agente	6
3.1. Descripción del prototipo funcional implementado	6
3.2. Capturas de pantalla y evidencia de interacción	7
3.3. Funcionalidades implementadas	10
3.4. Funcionalidades pendientes	10
3.5. Limitaciones técnicas actuales de la PoC	11
4. Diseño metodológico del estudio	11
4.1. Tipo de estudio	11
4.2. Condiciones del estudio	12
4.3. Participantes	12
4.4. Criterios de inclusión	12
4.5. Criterios de exclusión	12
4.6. Plan de reclutamiento	13
4.7. Consideraciones éticas	13
4.8. Prueba piloto previa y tarea de práctica	13
4.9. Plan de contingencia ante fallos técnicos	14
5. Métricas	14
5.1. Métricas de experiencia de usuario	14
5.2. Métricas de percepción social del agente	14
5.3. Métricas operativas	15
5.4. Métrica de concordancia humano-IA	15
6. Instrumentos de recolección de datos	15
6.1. UEQ-S	15
6.2. Godspeed	16
6.3. Pregunta abierta post-interacción	16
6.4. Logs de interacción	16
7. Protocolos de interacción	16
7.1. Escenario 1: Comprensión general del diseño de bases de datos	16
7.2. Escenario 2: Diferencia entre clave primaria y clave foránea	17

8. Prueba de Concepto implementada	17
8.1. Propósito de la PoC	17
8.2. Integración de componentes	18
8.3. Flujo técnico de ejecución	18
9. Repositorio, reproducibilidad y video de demostración	19
9.1. Organización del repositorio	19
9.2. Instrucciones de ejecución	20
9.3. Seguridad y manejo de credenciales	20
9.4. Video de demostración	20
9.5. Estado de reproducibilidad	21
10. Nota sobre referencias utilizadas	21

Tabla de figuras

Figura 1. Despliegue de Consentimiento Informado	7
Figura 2. Condición A: agente virtual corporizado con avatar visual básico.	8
Figura 3. Condición B: interfaz conversacional textual plana	8
Figura 4. Evidencia de interacción real con el agente académico.	9
Figura 5. Pantalla de instrumentos post-interacción.	9
Figura 6. Resumen de evaluaciones generadas (Verde - Usuario, Morado - IA)	10
Figura 7. Estructura del proyecto	19

1. Introducción

El presente documento corresponde al Entregable 2 del proyecto individual del curso PF-3311 Agentes Virtuales Inteligentes. Esta entrega marca la transición entre la propuesta conceptual presentada en el Entregable 1 y el desarrollo de una primera Prueba de Concepto funcional del agente virtual.

El proyecto propone construir y evaluar un agente virtual corporizado orientado a brindar apoyo académico básico en conceptos introductorios de bases de datos. La investigación se centra en analizar la experiencia de usuario generada durante la interacción con el agente y, de manera complementaria, comparar las valoraciones reportadas por usuarios humanos con una evaluación generada por un segundo modelo de lenguaje.

Este documento presenta el avance metodológico y técnico del proyecto. En particular, documenta los cambios incorporados a partir de la retroalimentación recibida en el Entregable 1, el diseño metodológico del estudio de evaluación, las métricas seleccionadas, los instrumentos de recolección de datos y los protocolos de interacción que serán utilizados en la Prueba de Concepto.

Nota de revisión. Esta versión del Entregable 2 incorpora las correcciones señaladas en la retroalimentación docente: la declaración explícita del tipo de estudio (Sección 4.1), el detalle del proceso de selección y asignación de participantes (Sección 4.6), el refuerzo de la anonimización y del identificador único y consistente (Sección 4.7), la inclusión de una prueba piloto previa y de una tarea de práctica para mitigar el novelty effect (Sección 4.8), la incorporación de un plan de contingencia ante fallos técnicos (Sección 4.9) y la consolidación del análisis de concordancia humano-IA (Sección 5.4).

2. Resumen de cambios desde el Entregable 1

A partir de la retroalimentación recibida en el Entregable 1, se realizaron ajustes metodológicos orientados a fortalecer la coherencia interna del proyecto y preparar su implementación como Prueba de Concepto.

En primer lugar, se precisó el diseño de evaluación del agente, diferenciando entre dos niveles de comparación. El primer nivel corresponde a una comparación experimental entre dos condiciones de interfaz: una condición con agente virtual corporizado y una condición de control basada en una interfaz conversacional textual plana. Esta comparación permite aislar el posible efecto del embodiment visual sobre la experiencia de usuario. El segundo nivel corresponde a una comparación metodológica entre las evaluaciones UX reportadas por usuarios humanos y las evaluaciones generadas por un modelo de lenguaje evaluador.

En segundo lugar, se ajustó la arquitectura de uso de modelos de lenguaje. La propuesta original contemplaba el uso general de un modelo de lenguaje para operar el agente y apoyar la evaluación. Sin embargo, para reducir el riesgo de circularidad metodológica, se definió el uso de dos modelos con funciones diferenciadas. El modelo LLM-A será utilizado como motor conversacional del agente virtual, mientras que el modelo LLM-B será utilizado como

evaluador complementario de la experiencia de usuario a partir de las transcripciones o descripciones controladas de las sesiones.

En tercer lugar, se reformuló la segunda pregunta de investigación para incorporar un criterio cuantitativo de concordancia. Se utilizará el coeficiente de correlación intraclase, ICC, como métrica estadística para comparar las puntuaciones humanas con las puntuaciones generadas por LLM-B. Como referencia exploratoria mínima se considerará $ICC \geq 0.70$, y se contrastará si los resultados se aproximan o superan $ICC \geq 0.75$, umbral asociado con buena confiabilidad.

En cuarto lugar, se concretaron los instrumentos de evaluación. Se definió el uso de UEQ-S como instrumento principal para medir experiencia de usuario, complementado con dimensiones seleccionadas de la escala Godspeed para evaluar antropomorfismo, simpatía, inteligencia y seguridad percibidas. Además, se incorporará una pregunta abierta post-interacción para recoger observaciones cualitativas breves.

Finalmente, se documentó una limitación metodológica importante: la evaluación generada por LLM-B se realizará a partir de una transcripción o descripción textual controlada de la interacción. Por tanto, no podrá evaluar directamente dimensiones multimodales como tono de voz, gestos complejos, microexpresiones, movimiento ocular, fluidez de animación o tiempo de respuesta real asociado al comportamiento corporal del agente.

3. Estado actual del agente

3.1. Descripción del prototipo funcional implementado

La Prueba de Concepto desarrollada corresponde a una aplicación web funcional orientada a demostrar la viabilidad técnica de la arquitectura propuesta. El prototipo integra una interfaz de interacción conversacional, un backend desarrollado con FastAPI, conexión configurable con un modelo de lenguaje, registro controlado de sesiones, aplicación de instrumentos UX y preparación del flujo para evaluación complementaria mediante un segundo modelo de lenguaje.


El agente cumple el rol de asistente académico básico para explicar conceptos introductorios de bases de datos. Su comportamiento está limitado al dominio del proyecto y busca ofrecer respuestas breves, claras, pedagógicas y comprensibles. El objetivo de esta versión no es construir un agente final completamente multimodal, sino demostrar que los componentes principales de la arquitectura pueden comunicarse entre sí y apoyar el protocolo de evaluación definido.

La PoC implementa dos condiciones de interfaz. La Condición A presenta una interfaz con avatar visual básico, orientada a representar al agente virtual corporizado. Esta condición permite que el participante perciba una entidad visual asociada a la interacción conversacional. La Condición B presenta una interfaz conversacional textual plana, sin avatar ni representación corporal del agente. Ambas condiciones mantienen el mismo dominio académico, el mismo tipo de tarea y el mismo motor conversacional, con el fin de aislar el posible efecto del embodiment visual sobre la experiencia de usuario.

A nivel funcional, el prototipo permite iniciar una sesión de evaluación, generar o asociar un identificador anónimo de participante, seleccionar o asignar una condición experimental, interactuar con el agente, registrar la transcripción de la conversación y completar instrumentos post-interacción. La sesión queda documentada mediante datos operativos básicos, tales como condición asignada, duración aproximada, número de turnos y contenido conversacional necesario para el análisis posterior.

3.2. Capturas de pantalla y evidencia de interacción

En esta sección se incorporarán capturas de pantalla del prototipo en funcionamiento para evidenciar el estado actual del agente y sus condiciones experimentales.



Prueba de Concepto del Agente Virtual Académico

Esta actividad forma parte de un proyecto académico del curso **PF-3311 Agentes Virtuales Inteligentes**. La prueba consiste en interactuar brevemente con un sistema conversacional que explica conceptos básicos de bases de datos.

El objetivo es valorar la experiencia de uso del prototipo bajo dos posibles condiciones: una interfaz con avatar visual básico y una interfaz textual sin avatar.

Condiciones de participación:

- La participación es voluntaria.
- No se solicitará nombre, cédula, correo, teléfono ni datos personales.
- El sistema generará automáticamente un ID anónimo de participante.
- La interacción será registrada únicamente con fines académicos.
- Puede finalizar la prueba en cualquier momento.

☐ Confirmo que lei la información anterior y acepto participar voluntariamente.

Condición experimental:

Asignación aleatoria

Para pruebas técnicas puede seleccionar una condición específica. Para una aplicación formal, se recomienda usar asignación aleatoria.

Iniciar interacción

Figura 1. Despliegue de Consentimiento Informado



Figura 2. Condición A: agente virtual corporizado con avatar visual básico.




Figura 3. Condición B: interfaz conversacional textual plana



Figura 4. Evidencia de interacción real con el agente académico.

Cuestionario UX breve

Evalúe su experiencia con el agente virtual. Use una escala de 1 a 7.

1 = valoración más negativa 7 = valoración más positiva

UEQ-S

1. Obstruivo — Apoyador	<input type="range"/>	4
2. Complicado — Fácil	<input type="range"/>	4
3. Ineficiente — Eficiente	<input type="range"/>	4
4. Confuso — Claro	<input type="range"/>	4
5. Aburrido — Emocionante	<input type="range"/>	4
6. No interesante — Interesante	<input type="range"/>	4
7. Convencional — Original	<input type="range"/>	4
8. Común — Novedoso	<input type="range"/>	4

Godspeed reducido

Evalúe cómo percibió al agente durante la interacción. Use la misma escala de 1 a 7.

Antropomorfismo		
Artificial — Natural	<input type="range"/>	4
Mecánico — Humano	<input type="range"/>	4
Simpatía		
Antipático — Simpatético	<input type="range"/>	4
Desagradable — Agradable	<input type="range"/>	4
Inteligencia percibida		
Incompetente — Competente	<input type="range"/>	4
Ignorante — Inteligente	<input type="range"/>	4
Seguridad percibida		
Inseguro — Seguro	<input type="range"/>	4
Inquietante — Tranquilizador	<input type="range"/>	4

¿Qué aspecto del agente virtual le pareció más positivo o qué mejoraría?

Escriba un comentario breve...

Guardar evaluación UX

Figura 5. Pantalla de instrumentos post-interacción.



Figura 6. Resumen de evaluaciones generadas (Verde - Usuario, Morado - IA)

Estas capturas permitirán mostrar que la PoC no solo describe la arquitectura propuesta, sino que implementa un flujo funcional de interacción, registro y evaluación.

3.3. Funcionalidades implementadas

Las funcionalidades implementadas actualmente son:

- Interfaz web inicial para la interacción con el prototipo.
- Condición A con avatar visual básico.
- Condición B con interfaz textual plana.
- Generación o asociación de ID anónimo de participante.
- Selección o asignación de condición experimental.
- Interacción conversacional con el agente académico.
- Conexión configurable con el modelo conversacional LLM-A.
- Registro de sesiones y transcripciones.
- Aplicación de instrumentos UX post-interacción.
- Registro de respuestas humanas de UEQ-S, Godspeed reducido y pregunta abierta.
- Evaluación complementaria de la sesión mediante LLM-B.
- Almacenamiento local de resultados para análisis posterior.
- Separación lógica entre interacción del agente, evaluación humana y evaluación generada por IA.

3.4. Funcionalidades pendientes

Las funcionalidades pendientes o por consolidar son:

- Mejorar el diseño visual final del avatar corporizado.

- Mejorar la integración del diseño visual con la salida de voz del agente.
- Mejorar la interfaz gráfica del sistema:
 - separar evaluaciones de la interfaz principal del agente,
 - mejorar la ubicación del agente para hacerlo protagonista,
 - incluir agradecimiento al participante al finalizar la sesión,
 - manejar de forma más discreta los resultados de las evaluaciones (la visualización comparativa de evaluaciones humano-IA se considera una funcionalidad de apoyo para el investigador y para la demostración técnica de la PoC. En una sesión formal de evaluación, esta información no deberá mostrarse al participante antes ni durante la aplicación de los instrumentos),
 - simplificar los textos que se le muestran al usuario (contenido menos técnico).
- Agregar instrucciones de entrada por voz (sujeto a tiempo disponible para implementación).

3.5. Limitaciones técnicas actuales de la PoC

Entre las limitaciones actuales de la PoC se reconoce que el embodiment es visual y básico. El prototipo no incorpora todavía gestos complejos, expresiones faciales avanzadas, seguimiento ocular, voz expresiva ni animación corporal completa. Por esta razón, la evaluación se enfocará en la experiencia de interacción textual con soporte visual básico, y no en una evaluación multimodal completa del comportamiento corporal del agente.

Además, la evaluación generada por LLM-B depende de la transcripción o descripción controlada de la sesión. Esto significa que el modelo evaluador no observa directamente la interacción visual ni corporal, sino que interpreta la información registrada. Por tanto, sus resultados se considerarán una evaluación complementaria y exploratoria, no una sustitución de la experiencia humana.

4. Diseño metodológico del estudio

4.1. Tipo de estudio

El estudio se plantea como una Prueba de Concepto con evaluación piloto controlada. Esta decisión responde al alcance del curso y a la necesidad de demostrar la viabilidad técnica y metodológica del agente sin realizar todavía una evaluación amplia con usuarios reales que requiera autorización formal de un comité ético.

La evaluación piloto permitirá validar el flujo de interacción, probar la asignación de condiciones, recolectar transcripciones de sesiones, aplicar instrumentos UX y ensayar el proceso de comparación entre evaluación humana y evaluación generada por LLM-B. El propósito principal no será generalizar resultados a una población amplia, sino identificar tendencias iniciales, problemas de diseño, limitaciones metodológicas y ajustes necesarios antes de una evaluación más robusta.

En términos de diseño experimental, el estudio adopta un diseño entre-sujetos (between-subjects): cada participante interactúa con una única condición —A (agente corporizado) o B

(interfaz textual plana)— y no es expuesto a la otra. Esta decisión evita efectos de arrastre, fatiga y aprendizaje entre condiciones, y reduce el riesgo de que la exposición previa a una interfaz sesgue la percepción de la otra. Como contrapartida, requiere asignar las condiciones de forma equilibrada entre participantes, lo cual se gestiona mediante asignación aleatoria balanceada, según se detalla en la Sección 4.6.

4.2. Condiciones del estudio

El estudio contempla dos condiciones de interfaz.

La Condición A corresponde al agente virtual corporizado. En esta condición, el participante interactuará con una interfaz web que presenta un avatar visual básico acompañado de una ventana conversacional. El agente cumplirá el rol de asistente académico para explicar conceptos introductorios de bases de datos.

La Condición B corresponde a la interfaz conversacional textual plana. En esta condición, el participante interactuará con el mismo sistema conversacional, el mismo modelo LLM-A, el mismo dominio temático y el mismo guion de tarea, pero sin avatar, animación ni representación corporal del agente.

La comparación entre ambas condiciones busca aislar el efecto del embodiment visual sobre la experiencia de usuario. Al mantener constantes el contenido académico, el modelo conversacional, el guion de interacción y los instrumentos de evaluación, las diferencias observadas podrán discutirse en relación con la modalidad de interfaz.

4.3. Participantes

La evaluación se realizará con una muestra pequeña, adecuada para una prueba piloto de curso. Se estima trabajar con aproximadamente 15 a 20 participantes o, si el alcance operativo lo requiere, con una evaluación piloto reducida o evaluación con expertos.

El perfil esperado corresponde a personas universitarias o con experiencia básica en el uso de herramientas digitales. No se requiere conocimiento avanzado en bases de datos, ya que el agente está diseñado para explicar conceptos introductorios. Sin embargo, se espera que los participantes puedan interactuar con una interfaz web y completar cuestionarios breves de experiencia de usuario.

4.4. Criterios de inclusión

Se considerarán los siguientes criterios de inclusión:

- Personas mayores de edad.
- Personas con capacidad para brindar consentimiento informado.
- Personas con experiencia básica en el uso de computadoras o navegadores web.
- Personas capaces de leer instrucciones y completar cuestionarios breves.
- Personas que acepten participar voluntariamente en la prueba piloto.

4.5. Criterios de exclusión

Se considerarán los siguientes criterios de exclusión:

- Personas que no acepten el consentimiento informado.
- Personas que no puedan completar la interacción mínima con el sistema.
- Personas que presenten dificultades técnicas que impidan el desarrollo de la sesión.
- Personas que no deseen que la transcripción anónima de la interacción sea utilizada para análisis académico.

4.6. Plan de reclutamiento

El reclutamiento se realizará de forma controlada y conveniente dentro del alcance del curso. Se podrá invitar a participantes mediante comunicación directa, redes académicas o compañeros voluntarios, aclarando que la actividad corresponde a una prueba piloto académica de bajo riesgo.

La participación será voluntaria. No se recopilarán datos sensibles, credenciales, documentos personales, números de identificación, direcciones, información médica ni datos privados. Cada participante será registrado mediante un identificador anónimo.

En cuanto a la selección y asignación de participantes, las personas se incorporan según los criterios de inclusión y exclusión definidos y se asignan a una de las dos condiciones mediante asignación aleatoria balanceada, procurando un número equivalente de sesiones por condición. Al iniciar la sesión, el sistema genera un identificador anónimo de participante que se mantiene único y consistente durante todo el flujo, de modo que la transcripción registrada por la base de datos automatizada, las respuestas de los instrumentos UX y la evaluación generada por el LLM-B queden vinculadas al mismo identificador, sin recurrir a datos personales.

4.7. Consideraciones éticas

El estudio se desarrollará como una prueba piloto académica. Antes de iniciar la sesión, se presentará un consentimiento informado que explicará el propósito del estudio, la duración estimada, el tipo de interacción, los datos que se registrarán y el uso académico de la información.

Los registros de interacción serán asociados únicamente a un ID anónimo. Las transcripciones se utilizarán para análisis de experiencia de usuario y para la evaluación complementaria mediante LLM-B. No se almacenará información personal identificable ni datos sensibles.

Para reforzar la anonimización, el identificador de participante es la única clave que vincula los distintos registros (sesión, transcripción, instrumentos UX y evaluación de la IA); no se almacena ningún dato que permita reidentificar a la persona y no se conserva correspondencia entre el identificador y su identidad una vez finalizada la sesión. Esta consistencia del identificador único entre la base de datos automatizada y las encuestas garantiza la trazabilidad del análisis sin comprometer la confidencialidad.

4.8. Prueba piloto previa y tarea de práctica

Antes de la recolección formal de datos se ejecuta una prueba piloto previa con un número reducido de personas, con el fin de verificar el flujo completo (consentimiento, asignación, interacción, instrumentos y registro), depurar los tiempos estimados y detectar problemas de

comprensión en las instrucciones. Asimismo, al inicio de cada sesión se incluye una breve tarea de práctica (warm-up): una interacción introductoria sencilla con el agente que no forma parte del análisis y cuyo objetivo es familiarizar a la persona con la interfaz y con la dinámica conversacional. Esta tarea de práctica busca mitigar el novelty effect —el sesgo derivado de la novedad de interactuar por primera vez con el sistema—, de manera que las puntuaciones reflejen la experiencia de uso y no la sorpresa inicial.

4.9. Plan de contingencia ante fallos técnicos

Se define una rutina estandarizada para el manejo de fallos técnicos durante las sesiones. Primero, ante un error transitorio del modelo de lenguaje o de la red (por ejemplo, un tiempo de espera agotado), el sistema reintenta la solicitud y registra el incidente en el log de la sesión. Segundo, si el modelo evaluador principal no está disponible —por ejemplo, por límites de cuota del servicio—, se recurre a un modelo de respaldo para completar la evaluación a partir de la misma transcripción, dejando constancia del modelo efectivamente utilizado. Tercero, si la falla impide completar la interacción mínima o la aplicación de los instrumentos, la sesión se marca como inválida y, de ser posible, se repite con un nuevo identificador anónimo, sin reutilizar datos parciales. Cuarto, todos los incidentes quedan documentados junto con el identificador de la sesión para su consideración en el análisis. Esta rutina procura un manejo uniforme y reproducible de los problemas técnicos y preserva la integridad de los datos recolectados.

5. Métricas

5.1. Métricas de experiencia de usuario

La experiencia de usuario se medirá principalmente mediante UEQ-S. Este instrumento permitirá obtener puntuaciones asociadas a dimensiones pragmáticas y hedónicas de la experiencia. Las métricas principales serán:

- Calidad pragmática.
- Calidad hedónica.
- Evaluación global de experiencia de usuario.

Estas métricas se conectan con la RQ1 porque permiten comparar las puntuaciones reportadas por usuarios humanos con las puntuaciones generadas por LLM-B sobre las mismas dimensiones del instrumento UX.

5.2. Métricas de percepción social del agente

De forma complementaria, se utilizarán dimensiones seleccionadas de la escala Godspeed. Las métricas consideradas serán:

- Antropomorfismo.
- Simpatía.
- Inteligencia percibida.
- Seguridad percibida.

Estas métricas permiten valorar si la presencia visual del agente corporizado incide en la forma en que el participante percibe al sistema. También ayudan a contextualizar la comparación entre la condición con avatar y la condición textual plana.

5.3. Métricas operativas

Además de los cuestionarios UX, se registrarán métricas operativas simples:

- Duración aproximada de la sesión.
- Número de intervenciones del participante.
- Finalización o no de la tarea.
- Condición asignada.
- Número de turnos conversacionales.
- Observaciones cualitativas breves.

Estas métricas no se utilizarán para evaluar rendimiento académico, sino para contextualizar la interacción y apoyar la interpretación de los resultados.

5.4. Métrica de concordancia humano-IA

Para responder la RQ2, se utilizará el coeficiente de correlación intraclase, ICC, como métrica de concordancia entre las puntuaciones reportadas por usuarios humanos y las puntuaciones generadas por LLM-B.

Como referencia exploratoria mínima se utilizará $ICC \geq 0.70$. Además, se reportará si los resultados alcanzan o superan $ICC \geq 0.75$, valor asociado con buena confiabilidad. Este análisis no será interpretado como validación definitiva del LLM evaluador, sino como una primera aproximación a su posible utilidad como apoyo metodológico en fases tempranas de evaluación UX.

Para consolidar el análisis de concordancia, se especifica que el ICC se estima bajo un modelo de dos vías de efectos aleatorios, con criterio de acuerdo absoluto y medida única — $ICC(A,1)$ —, por tratarse de dos fuentes de evaluación (humana y LLM-B) que valoran el mismo objeto. El análisis se complementa con estadística descriptiva por dimensión (medias y desviaciones), la diferencia media entre fuentes, el coeficiente de correlación de Pearson como indicador de consistencia lineal y una prueba de Wilcoxon de rangos con signo para contrastar diferencias sistemáticas entre ambas fuentes. La comparación se realiza emparejando, mediante el identificador único de cada sesión, la puntuación humana y la del LLM-B en cada dimensión del instrumento.

6. Instrumentos de recolección de datos

6.1. UEQ-S

UEQ-S será utilizado como instrumento principal para medir experiencia de usuario. Se aplicará después de que el participante complete la interacción con el agente o la interfaz textual asignada. El instrumento permitirá obtener puntuaciones breves y comparables sobre la percepción de la experiencia.

El mismo instrumento será completado posteriormente por LLM-B a partir de la transcripción o descripción controlada de la sesión. Esta duplicación del instrumento permitirá comparar las puntuaciones humanas con las puntuaciones generadas por el modelo de lenguaje.

6.2. Godspeed

Se utilizarán dimensiones seleccionadas de la escala Godspeed para evaluar percepciones sociales del agente. En particular, se considerarán antropomorfismo, simpatía, inteligencia y seguridad percibidas.

Este instrumento se aplicará después de la interacción, junto con UEQ-S. Su inclusión es relevante porque el estudio compara una condición corporizada con una condición textual plana, por lo que interesa observar si la presencia del avatar afecta la percepción social del sistema.

6.3. Pregunta abierta post-interacción

Se incluirá una pregunta abierta breve al final de la sesión:

¿Qué aspecto de la interacción le pareció más positivo, más problemático o más relevante?

Esta pregunta permitirá recoger información cualitativa que ayude a interpretar las puntuaciones de los cuestionarios y a detectar aspectos no capturados por los instrumentos cerrados.

6.4. Logs de interacción

El sistema registrará una transcripción o descripción controlada de la sesión. El registro incluirá únicamente:

- ID anónimo del participante.
- Condición asignada.
- Duración aproximada.
- Número de turnos.
- Finalización o no de la tarea.
- Contenido conversacional necesario para análisis posterior.

Estos logs serán utilizados para la comparación humano-IA y para la evaluación complementaria de LLM-B. No se almacenarán datos sensibles ni información personal identificable.

7. Protocolos de interacción

7.1. Escenario 1: Comprensión general del diseño de bases de datos

Contexto presentado al participante:

Usted está iniciando el estudio de conceptos básicos de bases de datos y necesita comprender qué significa diseñar una base de datos antes de implementarla.

Tareas específicas:

1. Solicite al agente una explicación sencilla sobre qué es el diseño de bases de datos.
2. Pida un ejemplo cotidiano que ayude a comprender el concepto.
3. Solicite una aclaración si alguna parte de la explicación no fue clara.
4. Confirme si la respuesta le ayudó a comprender el concepto.

Resultado esperado:

El participante recibe una explicación breve, clara y pedagógica sobre diseño de bases de datos, acompañada de un ejemplo comprensible. El agente debe mantener el dominio temático y evitar extenderse hacia temas no solicitados.

Duración estimada:

5 a 7 minutos.

7.2. Escenario 2: Diferencia entre clave primaria y clave foránea

Contexto presentado al participante:

Usted está revisando el diseño de una base de datos y necesita comprender la diferencia entre una clave primaria y una clave foránea.

Tareas específicas:

1. Pregunte al agente qué es una clave primaria.
2. Pregunte al agente qué es una clave foránea.
3. Solicite un ejemplo sencillo que compare ambos conceptos.
4. Pregunte cómo se relacionan las claves primarias y foráneas en una base de datos.
5. Confirme si la explicación fue clara o solicite una aclaración.

Resultado esperado:

El participante recibe una explicación diferenciada de clave primaria y clave foránea, con un ejemplo simple. El agente debe explicar la relación entre ambas sin introducir complejidad innecesaria.

Duración estimada:

5 a 8 minutos.

8. Prueba de Concepto implementada

8.1. Propósito de la PoC

La Prueba de Concepto tiene como propósito demostrar que la arquitectura propuesta para el agente virtual es técnicamente viable y que sus componentes principales pueden integrarse en un flujo funcional. Esta versión no pretende constituir un producto final, sino evidenciar la comunicación entre la interfaz web, el backend, el modelo conversacional, el registro de

sesiones, los instrumentos de evaluación UX y el módulo de evaluación complementaria mediante IA.

La PoC permite validar de manera preliminar el flujo completo requerido para el estudio: el participante acepta el consentimiento informado, interactúa con una de las condiciones experimentales, conversa con el agente académico, completa los instrumentos UX y genera datos que pueden ser utilizados posteriormente para comparar evaluación humana y evaluación generada por IA.

8.2. Integración de componentes

La PoC integra los siguientes componentes funcionales:

Componente	Función dentro de la PoC
Interfaz web	Presenta el consentimiento, las condiciones experimentales, el chat, los instrumentos UX y los resultados de la sesión.
Backend FastAPI	Gestiona las rutas de interacción, sesión, evaluación humana, evaluación IA y almacenamiento local de datos.
LLM-A	Genera las respuestas conversacionales del agente académico durante la interacción.
LLM-B	Evalúa la transcripción o descripción controlada de la sesión como evaluador complementario.
Registro de sesiones	Almacena el ID anónimo, condición asignada, turnos conversacionales y datos operativos.
Instrumentos UX	Permiten recolectar respuestas humanas mediante UEQ-S, Godspeed reducido y pregunta abierta.
Almacenamiento local	Organiza sesiones, transcripciones, evaluaciones humanas y evaluaciones generadas por IA para análisis posterior.

Esta integración demuestra que la arquitectura no se limita a una propuesta conceptual, sino que ya cuenta con una implementación funcional que conecta los componentes necesarios para ejecutar el estudio piloto.

8.3. Flujo técnico de ejecución

El flujo técnico de la PoC se organiza de la siguiente manera:

1. El participante accede a la aplicación web.
2. El sistema presenta el consentimiento informado.
3. Se genera o asocia un identificador anónimo de participante.
4. El sistema asigna o permite seleccionar una condición experimental.
5. El participante interactúa con el agente mediante la interfaz correspondiente.

6. El backend envía los mensajes al modelo LLM-A.
7. LLM-A genera respuestas académicas dentro del dominio de bases de datos.
8. El sistema registra los turnos conversacionales y la transcripción de la sesión.
9. El participante completa UEQ-S, Godspeed reducido y pregunta abierta.
10. El sistema almacena las respuestas humanas y los datos operativos.
11. LLM-B puede procesar la transcripción para generar una evaluación UX complementaria.
12. Los datos quedan disponibles para análisis descriptivo y cálculo posterior de concordancia.

9. Repositorio, reproducibilidad y video de demostración

9.1. Organización del repositorio

El repositorio del proyecto se encuentra disponible en GitHub y contiene la documentación, el código fuente de la Prueba de Concepto, los instrumentos de evaluación y los archivos necesarios para reproducir el prototipo de manera local.

La estructura general del repositorio se organiza de la siguiente manera:




Figura 7. Estructura del proyecto

La carpeta /docs contiene los documentos formales del proyecto y el protocolo HTML adaptado. La carpeta /prototype contiene la implementación de la PoC. La carpeta /evaluation agrupa instrumentos, protocolo y datos de evaluación. La carpeta /prompts contiene los prompts utilizados para delimitar el comportamiento del agente conversacional y del evaluador basado en IA.

9.2. Instrucciones de ejecución

El README del repositorio incluye las instrucciones necesarias para ejecutar la PoC localmente. De forma general, el flujo de ejecución será el siguiente:

```
cd prototype/src  
  
python -m venv venv  
  
venv\Scripts\activate  
  
pip install -r requirements.txt  
  
uvicorn app.main:app --reload
```

Una vez iniciado el servidor, la aplicación podrá abrirse desde el navegador en la dirección local indicada por FastAPI, usualmente:

```
http://127.0.0.1:8000
```

El README también indica cómo configurar el archivo .env, cómo seleccionar o probar las condiciones experimentales A y B, cómo ejecutar una sesión de prueba y dónde se almacenan los resultados generados por la aplicación.

9.3. Seguridad y manejo de credenciales

El repositorio no incluye API keys, tokens, credenciales ni datos personales. Las variables sensibles se gestionan mediante un archivo .env, el cual debe estar excluido del repositorio mediante .gitignore.

El archivo .env incluye variables como:

```
GEMINI_API_KEY=colocar_api_key_local  
  
GEMINI_MODEL=nombre_del_modelo
```

El proyecto incluye un archivo de ejemplo, *.env.example*, sin credenciales reales, para que el profesor pueda identificar qué variables debe configurar localmente si desea ejecutar la PoC.

También se excluyen del repositorio carpetas como:

```
prototype/src/data/  
  
prototype/src/venv/  
  
__pycache__/  
  
.env
```

De esta manera se reduce el riesgo de publicar información sensible o resultados de sesiones piloto.

9.4. Video de demostración

El video muestra lo descrito a continuación:

- acceso inicial a la aplicación;
- aceptación del consentimiento informado;
- visualización de la Condición A con agente corporizado;
- interacción real con el agente académico;
- visualización de la Condición B como interfaz textual plana;
- aplicación de instrumentos post-interacción;
- evidencia del registro o resumen de evaluación generado por el sistema.

El video está publicado como enlace no listado en YouTube y está incorporado en el README del repositorio.

Enlace al video de demostración:

<https://youtu.be/jhzsNL0CJfw>

9.5. Estado de reproducibilidad

La PoC se considera reproducible en entorno local siempre que se configuren las dependencias, las variables de entorno y el modelo de lenguaje correspondiente. La aplicación no requiere despliegue en la nube para demostrar su funcionamiento básico.

Para verificar la reproducibilidad, se recomienda ejecutar una sesión de prueba en cada condición experimental. En la Condición A se debe validar la carga del avatar visual básico, la interacción conversacional y el registro de la sesión. En la Condición B se debe validar la interfaz textual plana, la interacción con el mismo motor conversacional y el almacenamiento equivalente de los datos. Finalmente, se debe comprobar que los instrumentos post-interacción se despliegan correctamente y que los resultados quedan almacenados para análisis posterior.

10. Nota sobre referencias utilizadas

El presente documento se basa en la revisión de literatura y en las referencias académicas consolidadas en el Entregable 1 del proyecto. En particular, se retoman las fuentes relacionadas con agentes conversacionales basados en modelos de lenguaje, agentes virtuales corporizados, evaluación UX, uso de LLM como apoyo evaluativo y consideraciones éticas en estudios HCI/IA.

Asimismo, el diseño metodológico del Entregable 2 utiliza las referencias complementarias incorporadas en la versión corregida del Entregable 1 para fundamentar los instrumentos y métricas seleccionadas: UEQ-S para experiencia de usuario, Godspeed para percepción social del agente y el coeficiente de correlación intraclase, ICC, para el análisis de concordancia humano-IA.

Por tanto, este documento no repite íntegramente la sección bibliográfica del Entregable 1, sino que la toma como base académica del diseño metodológico y técnico presentado en esta segunda entrega.