

Evaluación UX Aumentada con IA para Agentes Virtuales Corporizados: Comparación Exploratoria entre Usuarios Humanos y un Modelo de Lenguaje

Deivert Guiltrichs Cordero

Escuela de Ciencias de la Computación e Informática

Programa de Posgrado en Computación e Informática

Universidad de Costa Rica

San José, Costa Rica

PF-3311 Agentes Virtuales Inteligentes — I Ciclo, 2026

Resumen—La evaluación de la experiencia de usuario (UX) en agentes virtuales basados en modelos de lenguaje (LLM) enfrenta retos crecientes: los sistemas son generativos, contextuales y, en ocasiones, multimodales, por lo que aplicar instrumentos clásicos de forma aislada puede resultar insuficiente. Este trabajo presenta el diseño, la implementación y la evaluación piloto exploratoria de un agente virtual corporizado orientado a brindar apoyo académico en conceptos introductorios de bases de datos. El sistema se desarrolló como una Prueba de Concepto (PoC) web con backend en FastAPI e integración configurable con un LLM conversacional. La PoC implementa dos condiciones de interfaz —un agente con avatar visual básico (Condición A) y una interfaz textual plana (Condición B)— que comparten el mismo motor conversacional, dominio y guion de tarea, con el fin de aislar el efecto del *embodiment* visual. Como objetivo metodológico central, se compara la evaluación UX reportada por usuarios humanos (UEQ-S y dimensiones de Godspeed) con la evaluación generada por un segundo modelo de lenguaje (LLM-B) sobre la misma transcripción, utilizando el coeficiente de correlación intraclase (ICC) como métrica exploratoria de concordancia. Se evaluaron diez sesiones (cinco por condición), cada una valorada por el usuario humano y por el LLM-B. El evaluador automático tendió a puntuar por debajo del usuario humano, con la mayor divergencia en la calidad hedónica. La concordancia fue dimensión-dependiente: moderada en calidad pragmática ($ICC \approx 0,69$) y baja en calidad hedónica ($ICC \approx 0,22$), con un ICC global cercano a 0,40, por debajo del umbral exploratorio de 0,70. Asimismo, el avatar visual básico no mejoró la experiencia ni la percepción social frente a la interfaz textual. Se concluye que un LLM puede aportar como evaluador complementario en aspectos pragmáticos durante fases tempranas de diseño, pero no sustituye la evaluación humana, en especial en las dimensiones afectivas y multimodales.

Index Terms—agentes virtuales corporizados, experiencia de usuario, evaluación UX, modelos de lenguaje, LLM como evaluador, *embodiment*, UEQ-S, Godspeed, ICC

I. INTRODUCCIÓN

Los agentes conversacionales basados en modelos de lenguaje (LLM) han adquirido una presencia creciente en contextos educativos, de asistencia y de interacción humano-computadora, debido a su capacidad para sostener diálogos

naturales, adaptar explicaciones y participar en intercambios de múltiples turnos [1], [2]. A diferencia de los chatbots tradicionales basados en reglas, estos sistemas generan respuestas flexibles y contextuales, lo que abre la posibilidad de construir agentes virtuales que apoyen procesos de aprendizaje y expliquen conceptos académicos [3], [4], [5].

Sin embargo, el valor de estos agentes no puede evaluarse únicamente desde la precisión textual de sus respuestas. Cuando una persona interactúa con un agente virtual, en especial si posee una representación visual o corporizada, la experiencia de usuario no depende solo de *qué* responde el sistema, sino también de *cómo* se percibe la interacción. Elementos como confianza, claridad, naturalidad, presencia social, utilidad percibida, satisfacción y credibilidad se vuelven relevantes para determinar si el agente resulta adecuado en un contexto académico [1], [6], [7].

Esta situación genera un reto metodológico: la evaluación UX de sistemas de IA no puede limitarse a aplicar instrumentos tradicionales de forma mecánica. Los sistemas generativos producen resultados no siempre previsibles y generan percepciones sociales en los usuarios, por lo que instrumentos como SUS, UEQ o NASA-TLX, aunque útiles, pueden resultar insuficientes si se emplean de forma aislada [8], [9]. En este escenario surge una línea emergente: el uso de LLM como apoyo a la evaluación UX [9]. No obstante, un LLM no *experimenta* la interacción; produce una valoración generada a partir de la información disponible, posiblemente útil para identificar patrones, pero no equivalente a la percepción humana [10].

Contribución. Este trabajo desarrolla y evalúa, de manera exploratoria y controlada, un agente virtual corporizado de apoyo académico, y compara dos fuentes de valoración UX: la reportada por usuarios humanos y la generada por un segundo modelo de lenguaje sobre el mismo escenario de interacción. El objetivo no es demostrar que el modelo pueda reemplazar a los usuarios, sino analizar si puede funcionar como herramienta complementaria en fases tempranas de evaluación UX, identificando concordancias, diferencias y límites

metodológicos.

Estructura. La Sección II revisa los trabajos relacionados; la Sección III describe la arquitectura e implementación del agente; la Sección IV detalla el diseño metodológico; la Sección V presenta los resultados de la evaluación piloto; la Sección VI ofrece el análisis y la discusión; y la Sección VII expone conclusiones y trabajo futuro.

II. TRABAJOS RELACIONADOS

La revisión de literatura se construyó a partir de fuentes de ACM y Springer, mediante una cadena de búsqueda orientada a recuperar estudios sobre agentes virtuales, experiencia de usuario, evaluación humana, modelos de lenguaje y contexto educativo.

II-A. Agentes conversacionales basados en modelos de lenguaje

Los agentes basados en LLM procesan lenguaje de forma contextual y generan respuestas adaptadas al flujo del diálogo [1], [11], [2]. Guan et al. [2] explican que un agente conversacional basado en LLM no es un modelo que responde a un *prompt* aislado, sino un sistema capaz de integrar memoria, planificación y uso de herramientas. A la vez, la literatura advierte que estas capacidades dificultan que los usuarios comprendan los límites reales del sistema, sus fuentes y sus posibles errores [12], por lo que el diseño debe comunicar con claridad su alcance.

II-B. Embodiment, antropomorfismo y experiencia de usuario

El grado de *embodiment*, la voz, la expresión visual, los gestos y la personalidad del agente influyen en cómo los usuarios interpretan la interacción [1], [7], [8]. Schlesener et al. [1] distinguen niveles de forma antropomórfica —chatbot textual, chatbot con texto a voz y *embodied conversational agent*— y muestran que el *embodiment* y los comportamientos basados en *Theory of Mind* afectan la confianza, el antropomorfismo, la presencia, la usabilidad y la UX. La personalidad también es relevante: Byeon et al. [6] hallaron que la personalidad percibida de un chatbot afecta la credibilidad de la información, y Han et al. [7] muestran que los LLM pueden generar comportamientos alineados con rasgos de personalidad reconocibles por los usuarios.

II-C. Agentes conversacionales en educación

En educación, estos agentes se han utilizado para responder consultas, apoyar tareas, ofrecer retroalimentación y personalizar la interacción [3], [4], [5], [13]. Sedrakyan et al. [3] destacan su potencial, pero advierten que los diseños actuales suelen carecer de fundamentos en ciencias del aprendizaje. Wong y Chan [5] señalan que la personalización y la evaluación empírica de percepciones siguen requiriendo más investigación. El estudio de AIValue [4] presenta un agente pedagógico aumentado con LLM, evaluado mediante un diseño mixto, que reporta usabilidad aceptable junto con limitaciones técnicas y menor conexión personal frente a la interacción cara a cara.

II-D. Evaluación UX en sistemas de inteligencia artificial

La evaluación UX de sistemas de IA enfrenta desafíos distintos, pues las respuestas son dinámicas y generan percepciones sociales [9], [2]. Zheng et al. [9] plantean que instrumentos como SUS, UEQ y NASA-TLX pueden ser insuficientes para capturar la complejidad de las interacciones humano-IA, especialmente ante confianza, *engagement* emocional y comportamientos multimodales. La evaluación de sistemas conversacionales puede combinar métricas subjetivas y objetivas, como en EventChat [14].

II-E. Modelos de lenguaje como apoyo evaluativo

EvAlignUX [9] ayuda a investigadores de HCI a explorar métricas de evaluación, resultados esperados y riesgos. Yun et al. [15] muestran que los LLM pueden diversificar preguntas de entrevistas administradas por agentes virtuales conservando propiedades psicométricas. Estos antecedentes respaldan el uso del LLM como apoyo a la evaluación, no como sustituto: el modelo no “vive” la experiencia, sino que produce una valoración a partir de la información disponible.

II-F. Riesgos metodológicos de comparar humanos y LLM

Shahania et al. [10] demostraron que los LLM pueden superar controles de calidad de encuestas e imitar patrones de respuesta humanos en formatos estructurados. Si un LLM responde un cuestionario UX de forma similar a un humano, ello no implica que haya experimentado la interacción. Por ello, la comparación debe analizar concordancias y diferencias sin asumir equivalencia, tratando al LLM como evaluador complementario.

II-G. Consideraciones éticas

Aun en el marco de un curso, el proyecto involucra interacción con participantes y recolección de datos de percepción, por lo que deben considerarse principios de ética en investigación HCI/IA: participación voluntaria, consentimiento informado, minimización de datos y confidencialidad [16].

II-H. Síntesis de la brecha

La literatura muestra avances en agentes basados en LLM, agentes corporizados, agentes educativos y herramientas de apoyo evaluativo [1], [3], [9], [2], [4], [5]. Persiste, sin embargo, una brecha en la comparación directa entre evaluaciones UX humanas y de un LLM sobre una misma interacción con un agente corporizado en contexto educativo. La contribución de este trabajo es exploratoria y metodológica.

III. DESARROLLO DEL AGENTE

III-A. Visión general de la arquitectura

La arquitectura se organiza en cinco componentes: (1) interfaz de usuario y visualización del agente; (2) módulo de interacción conversacional; (3) modelo de lenguaje para generación de respuestas (LLM-A); (4) módulo de evaluación UX aumentada con IA (LLM-B); y (5) registro controlado de interacciones. La Figura 1 resume el flujo conceptual.




Figura 1. Diagrama conceptual de la arquitectura: el usuario interactúa con la interfaz del agente, el LLM-A genera respuestas académicas, la interacción se registra y se aplican en paralelo el instrumento UX humano y la evaluación del LLM-B.

III-B. Implementación de la Prueba de Concepto

La PoC es una aplicación web funcional con *backend* en FastAPI y conexión configurable con un LLM. Gestiona el consentimiento informado, la generación de un identificador anónimo, la asignación de condición, la interacción, el registro de transcripciones y la aplicación de instrumentos post-interacción. El agente cumple el rol de asistente académico para conceptos introductorios de bases de datos, con respuestas breves, claras, pedagógicas y limitadas al dominio. El comportamiento se delimita mediante un *prompt* de sistema; el LLM-B se rige por un *prompt* evaluador que completa el mismo instrumento a partir de la transcripción. Esta separación LLM-A/LLM-B reduce el riesgo de circularidad metodológica.

III-C. Condiciones de interfaz

La PoC implementa dos condiciones que comparten motor conversacional, dominio y guion de tarea, variando únicamente el *embodiment* visual: la **Condición A** presenta un avatar visual básico (Figura 2), y la **Condición B** es una interfaz textual plana sin avatar ni voz (Figura 3).

Ambas condiciones se sostienen sobre el mismo modelo conversacional (LLM-A), el mismo *prompt* de sistema, el mismo dominio académico —conceptos introductorios de bases de datos— y el mismo guion de tarea guiada, con idénticas restricciones de respuesta. De este modo, el único factor manipulado es la presencia o ausencia de la representación visual del agente. En la Condición A el avatar aporta presencia

en pantalla y señales sociales que indican al usuario que interactúa con una entidad virtual; en la Condición B la interacción es puramente textual, semejante a una interfaz de mensajería convencional, y funciona como *baseline*. Este aislamiento controlado de variables es el que permite atribuir cualquier diferencia observada principalmente al *embodiment* visual, de forma coherente con el diseño entre-sujetos descrito en la Sección IV.




Figura 2. Condición A: agente virtual corporizado con avatar visual básico durante una interacción real sobre diseño de bases de datos.




Figura 3. Condición B: interfaz conversacional textual plana, sin avatar ni voz, empleada como condición de control.

III-D. Funcionalidades y limitaciones técnicas

Se implementaron las dos condiciones, la generación de ID anónimo, la interacción con el agente, el registro de sesiones, la aplicación de UEQ-S, Godspeed reducido y pregunta abierta, la evaluación por LLM-B y el almacenamiento de resultados. Como limitación central, el *embodiment* es visual

y básico: no incorpora aún gestos complejos, expresiones faciales avanzadas, seguimiento ocular ni animación corporal completa. El LLM-B evalúa a partir de la transcripción, sin observar directamente la interacción visual o corporal.

IV. METODOLOGÍA

IV-A. Tipo de estudio y preguntas de investigación

El estudio es una Prueba de Concepto con evaluación piloto controlada, cuyo propósito no es generalizar sino validar el flujo, recolectar transcripciones, aplicar los instrumentos y ensayar la comparación humano-IA. Las preguntas son:

- **RQ1.** ¿Qué grado de concordancia existe entre las puntuaciones de UX reportadas por usuarios humanos y las generadas por un modelo de lenguaje evaluador, sobre una interacción con un agente virtual corporizado académico?
- **RQ2.** ¿En qué medida concuerdan, considerando como referencia exploratoria mínima un $ICC \geq 0,70$ y contrastando si se aproximan o superan el umbral de $ICC \geq 0,75$?
- **RQ3.** ¿Qué limitaciones, riesgos y consideraciones deben tomarse en cuenta al incorporar un LLM como evaluador complementario de UX en agentes corporizados?

IV-B. Diseño y condiciones

El diseño contempla dos niveles de comparación (Tabla I): una *comparación experimental* entre las Condiciones A y B, que aísla el efecto del *embodiment* manteniendo constantes contenido, guion, LLM-A e instrumentos; y una *comparación metodológica* entre la evaluación humana y la del LLM-B. El estudio adopta un diseño entre-sujetos (*between-subjects*): cada participante interactúa con una única condición y no es expuesto a la otra, lo que evita efectos de arrastre y de aprendizaje; las condiciones se asignan de forma aleatoria y balanceada.

Tabla I
NIVELES DE COMPARACIÓN DEL ESTUDIO

Nivel	¿Qué se compara?	Propósito
Comparación experimental	Condición A (corporizado) vs. Condición B (textual)	Analizar el impacto del <i>embodiment</i> visual en la UX.
Comparación metodológica	Evaluación humana vs. evaluación de LLM-B	Analizar si un LLM puede ser evaluador complementario de UX.

IV-C. Participantes

El perfil esperado corresponde a personas universitarias o con experiencia básica en herramientas digitales. Se aplicaron criterios de inclusión (mayoría de edad, consentimiento, experiencia básica con navegadores, voluntariedad) y de exclusión (no aceptar el consentimiento, no completar la interacción mínima o no autorizar el uso académico de la transcripción

anónima). Las personas se incorporaron por muestreo por conveniencia y se asignaron a una condición mediante asignación aleatoria balanceada. Al iniciar la sesión, el sistema genera un identificador anónimo único y consistente durante todo el flujo, de modo que la transcripción, las respuestas de los instrumentos UX y la evaluación del LLM-B quedan vinculadas al mismo identificador sin recurrir a datos personales.

IV-D. Instrumentos y métricas

La UX se midió con UEQ-S [17] (calidad pragmática, hedónica y puntaje global) y con dimensiones seleccionadas de Godspeed [18] (antropomorfismo, simpatía, inteligencia y seguridad percibidas). Se incluyó una pregunta abierta post-interacción. La concordancia humano-IA se estimó con el coeficiente de correlación intraclase (ICC) [19] bajo un modelo de dos vías, efectos aleatorios, acuerdo absoluto y medida única —ICC(A,1)—, complementado con estadística descriptiva, correlación de Pearson y una prueba de Wilcoxon. La Figura 4 muestra la pantalla de instrumentos.

Figura 4. Pantalla post-interacción con UEQ-S (escala 1–7) y Godspeed reducido, más la pregunta abierta.

IV-E. Protocolos de interacción

Se definieron dos escenarios de tarea guiada: comprensión general del diseño de bases de datos (5–7 min) y diferencia entre clave primaria y foránea (5–8 min). En ambos, el agente debe mantener el dominio temático y evitar extenderse a temas no solicitados.

IV-F. Procedimiento de recolección de datos

La sesión sigue nueve pasos: recepción, consentimiento e identificación anónima, asignación de condición, instrucciones neutras, interacción con el agente (10–15 min), registro de la sesión, aplicación de los instrumentos, evaluación por LLM-B y comparación. Para mitigar el *novelty effect*, cada sesión incluye al inicio una breve tarea de práctica (*warm-up*) que no forma parte del análisis; además, el protocolo se depuró mediante una prueba piloto previa. Se definió asimismo una rutina estandarizada de contingencia ante fallos técnicos: reintento y registro de errores transitorios; uso de un modelo evaluador de respaldo si el principal no está disponible; e invalidación y

repetición de la sesión, con un nuevo identificador, cuando la falla impide completar la interacción o los instrumentos.

V. RESULTADOS

V-A. Muestra y estado funcional del sistema

Se completaron diez sesiones válidas, balanceadas (cinco corporizado, cinco textual). El 100 % registró consentimiento, interacción, transcripción y evaluación humana y de LLM-B. Las sesiones tuvieron en promedio 5.7 turnos (rango 4–8) y una duración media de 356 s ($\approx$ 5,9 min; rango 143–570 s). La evaluación automática se generó con dos modelos (cinco con gpt-5.5-thinking y cinco con gemini-3.1-flash-lite). El modelo previsto era Gemini; durante parte de la recolección el servicio quedó temporalmente no disponible por límites de cuota, por lo que —conforme a la rutina de contingencia— esas evaluaciones se completaron con GPT a partir de las mismas transcripciones, dejando constancia del modelo utilizado. Ambos arrojaron puntajes globales medios próximos (4.12 y 4.45), por lo que se analizan de forma agregada como LLM-B, señalando esta heterogeneidad como limitación (Sección VI-C).

V-B. Comparación de la experiencia: humano vs. LLM-B

La Tabla II y la Figura 5 resumen las puntuaciones UEQ-S por fuente. En las tres dimensiones, el LLM-B puntuó por debajo del usuario humano, con diferencia mínima en pragmática (−0,62) y máxima en hedónica (−1,33). Las pruebas de Wilcoxon indican diferencias en el puntaje global ($p = 0,031$) y en la calidad hedónica ($p = 0,035$), y marginal en pragmática ($p = 0,051$). El evaluador automático mostró, así, un sesgo conservador más acentuado en lo afectivo.

Tabla II
UEQ-S POR FUENTE DE EVALUACIÓN (ESCALA 1–7; $N = 10$)

Dimensión UEQ-S	Humano (M $\pm$ DE)	LLM-B (M $\pm$ DE)	Δ
Calidad pragmática	5,65 $\pm$ 1,15	5,03 $\pm$ 1,20	−0,62
Calidad hedónica	4,88 $\pm$ 1,81	3,55 $\pm$ 1,14	−1,33
Puntaje global	5,26 $\pm$ 1,42	4,29 $\pm$ 0,91	−0,98




Figura 5. Puntuaciones UEQ-S por fuente (media $\pm$ DE). El LLM-B (morado) puntuó sistemáticamente por debajo del usuario humano (verde), con la mayor brecha en la calidad hedónica. La línea discontinua marca el punto neutro (4).

V-C. Concordancia humano-IA (RQ1 y RQ2)

La concordancia interevaluador, estimada con ICC(A,1), muestra un patrón dimensión-dependiente (Tabla III): moderada en calidad pragmática (0.687; $p = 0,003$), próxima al umbral de 0.70; pobre en calidad hedónica (0.218); y de 0.400 en el puntaje global, por debajo de 0.70 y lejos de 0.75. La correlación lineal del puntaje global fue moderada pero no significativa (Pearson $r = 0,565$; $p = 0,089$): el LLM-B ordena las sesiones en una dirección similar a la humana, pero con un desplazamiento sistemático a la baja, como ilustra la Figura 6. Por tanto, en respuesta a la RQ2, la concordancia global no alcanza el umbral exploratorio mínimo; solo la calidad pragmática se aproxima. Los intervalos de confianza son amplios, lo esperable con $N = 10$, por lo que estos valores son una primera aproximación exploratoria.

Tabla III
CONCORDANCIA HUMANO-LLM-B POR DIMENSIÓN, ICC(A,1) ($N = 10$)

Dimensión	ICC(A,1)	IC 95 %	p	Interpr.
Calidad pragmática	0.687	[0,11, 0,91]	0.003	Moderada
Calidad hedónica	0.218	[−0,23, 0,68]	0.197	Pobre
Puntaje global	0.400	[−0,12, 0,79]	0.053	Pobre-reg.




Figura 6. Puntaje global humano vs. LLM-B por sesión. La línea discontinua representa el acuerdo perfecto; los puntos por debajo reflejan la subvaloración del evaluador automático.

V-D. Efecto del embodiment y percepción social

La comparación entre condiciones (Tabla IV) no evidenció mejora asociada al avatar. En la evaluación humana, el puntaje global fue ligeramente menor en la condición corporizada (5.13) que en la textual (5.40), y las cuatro dimensiones de Godspeed fueron también algo más bajas con avatar. Ninguna diferencia alcanzó significancia (Mann-Whitney, todas $p > 0,05$; la más cercana fue simpatía, $p = 0,068$). De forma exploratoria, la concordancia humano-IA fue mayor en la condición corporizada (ICC global = 0,654) que en la textual (0.234). Estos contrastes se reportan como tendencias descriptivas dado el reducido tamaño por grupo.

Tabla IV
EVALUACIÓN HUMANA POR CONDICIÓN (MEDIAS; $n = 5$ POR GRUPO)

Medida (evaluación humana)	Cond. A	Cond. B
UEQ-S — puntaje global	5.13	5.40
Godspeed — antropomorfismo	3.70	4.60
Godspeed — simpatía	5.00	6.00
Godspeed — inteligencia percibida	5.10	6.10
Godspeed — seguridad percibida	5.60	6.20

V-E. Hallazgos cualitativos

Los comentarios abiertos contextualizan las puntuaciones. En la condición corporizada, las observaciones recurrentes se refirieron a la voz sintetizada —lenta, pausada y poco natural—, con solicitudes de velocidad ajustable y respuestas ocasionalmente repetitivas. En la condición textual, se valoró la precisión y la rapidez, pero se señaló el uso de lenguaje técnico o siglas sin explicar, problemas de continuidad y el saludo repetido en cada turno. Estos señalamientos son consistentes con la menor calidad hedónica observada, especialmente con avatar, donde la voz lenta —un elemento multimodal que el LLM-B no percibe desde la transcripción— afectó la experiencia.

VI. ANÁLISIS Y DISCUSIÓN

VI-A. Interpretación frente a las preguntas de investigación

Respecto a la RQ1, el LLM-B completó el instrumento y produjo valoraciones plausibles y ordenadas de forma coherente con las humanas, pero la concordancia no fue homogénea: aceptable en lo pragmático y deficiente en lo hedónico. Respecto a la RQ2, el ICC global de 0.40 no alcanza el umbral exploratorio de 0.70; solo la calidad pragmática (0.69) se aproxima, lo que sugiere que la utilidad del LLM como evaluador complementario se concentra en la dimensión instrumental. Respecto a la RQ3, al evaluar solo la transcripción el LLM-B no percibe elementos multimodales —de forma notable, la voz lenta de la condición corporizada—, lo que explica su menor sensibilidad y mayor discrepancia en lo hedónico.

VI-B. Comparación con la literatura

El desplazamiento sistemático entre fuentes es coherente con Shahania et al. [10]: un LLM puede emitir respuestas estructuradas semejantes a las humanas sin haber experimentado la interacción. La baja concordancia afectiva concuerda con Zheng et al. [9], sobre la insuficiencia de los instrumentos clásicos ante el *engagement* emocional y lo multimodal. El rol del LLM como apoyo evaluativo y no como sustituto, en línea con EvAlignUX [9] y Yun et al. [15], resulta el encuadre adecuado. Finalmente, la ausencia de beneficio del avatar contrasta con la expectativa teórica del *embodiment* [1]: un *embodiment* básico con voz sintetizada deficiente no produjo la ganancia de presencia social esperada, lo que subraya que la calidad de ejecución multimodal condiciona su efecto.

VI-C. Limitaciones del estudio

El estudio es exploratorio y de alcance de curso. El tamaño muestral ($N = 10$; cinco por condición) produce intervalos de confianza amplios y subpotencia los contrastes entre condiciones, reportados como tendencias. La evaluación automática empleó dos modelos distintos —por la indisponibilidad temporal del modelo previsto (Gemini) por cuota, parte de las evaluaciones se realizaron con GPT—, lo que introduce heterogeneidad en el rol de LLM-B; aunque sus puntajes globales fueron próximos y se repartieron de forma pareja entre condiciones, lo idóneo sería fijar un único modelo evaluador. La evaluación del LLM-B depende de la transcripción y, por diseño, no observa la dimensión multimodal. Persiste un riesgo de circularidad parcial, mitigado mediante la separación LLM-A/LLM-B pero no eliminado.

VII. CONCLUSIONES Y TRABAJO FUTURO

Este trabajo diseñó, implementó y evaluó de forma exploratoria un agente virtual corporizado de apoyo académico, junto con un marco de comparación entre la evaluación UX humana y la generada por un segundo modelo de lenguaje. La PoC demostró un flujo funcional completo en dos condiciones que aíslan el *embodiment* visual, evaluado con diez sesiones balanceadas.

Los resultados muestran que el LLM-B puede aportar como evaluador complementario en la dimensión pragmática ($ICC \approx 0.69$), pero no en la hedónica ($ICC \approx 0.22$) ni en el conjunto global ($ICC \approx 0.40$), que no superan el umbral de 0.70. El evaluador automático tendió a subvalorar la experiencia, con la mayor brecha en lo afectivo, coherente con su incapacidad de percibir señales multimodales. Además, el avatar visual básico, con una voz sintetizada lenta, no mejoró la experiencia ni la percepción social frente a la interfaz textual. En síntesis, un LLM no sustituye la evaluación humana, pero puede funcionar como apoyo focalizado en aspectos pragmáticos en fases tempranas de diseño.

Como trabajo futuro se plantea ampliar y balancear la muestra para estrechar los intervalos del ICC; fijar un único modelo evaluador y calibrar su sesgo; incorporar a la evaluación descriptores de la dimensión multimodal o pasar a evaluación multimodal; y mejorar la ejecución del *embodiment* (voz natural y ajustable, mayor dinamismo) antes de volver a contrastar su efecto.

Proyección de publicación. Se proyecta continuar con esta línea de trabajo. La intención es ampliar y balancear la muestra, fijar un único modelo evaluador y refinar el protocolo a partir de los hallazgos del piloto, para —sujeto a la aprobación del Comité Ético Científico de la Universidad de Costa Rica— ejecutar una evaluación formal con miras a una publicación académica. Los resultados aquí presentados se consideran evidencia preliminar que respalda esa continuación.

REFERENCIAS

- [1] E. A. Schlesener, M. Ziolkowski, S.-K. Wong, B. Westmoreland, and S. V. Babu, “‘Am I Understood?’: How the Interplay between Embodiment and Theory of Mind Behavior Affects LLM-Based Conversational Agents on Perceived Trust, Anthropomorphism, Presence, Usability, and

- User Experience,” *ACM Trans. Interact. Intell. Syst.*, vol. 16, no. 2, Art. 11, 2026.
- [2] S. Guan, J. Wang, J. Bian, B. Zhu, J.-G. Lou, and H. Xiong, “Evaluating LLM-Based Agents for Multi-Turn Conversations: A Survey,” *ACM Trans. Intell. Syst. Technol.*, vol. 17, no. 4, Art. 85, 2026.
 - [3] G. Sedrakyan, S. Borsci, S. van den Berg, J. van Hillegersberg, and B. Veldkamp, “Design Implications for Next Generation Chatbots with Education 5.0,” in *New Technology in Education and Training*, Springer, 2024.
 - [4] H. Yusuf, A. Money, and D. Daylamani-Zad, “Towards Reducing Teacher Burden in Performance-Based Assessments Using AIvaluate,” *Education and Information Technologies*, Springer, 2025.
 - [5] A. K. L. Wong and L. L. Chan, “Integrating Chatbots with Learning Management Systems for Personalized Learning: A Comprehensive Review and Framework Proposal—the CLIF,” *Discover Education*, Springer, 2025.
 - [6] H. Byeon, U. Oh, and G. Hsieh, “Understanding the Effects of Conversational Agent Personality on the Credibility of LLM-Based Conversational Search,” in *Proc. 2026 ACM SIGIR Conf. Human Information Interaction and Retrieval*, 2026.
 - [7] B. Han, D. Kwon, S. Lin, K. Shrestha, and J. Gratch, “Can LLMs Generate Behaviors for Embodied Virtual Agents Based on Personality Traits?,” in *Proc. ACM Int. Conf. Intelligent Virtual Agents*, 2025.
 - [8] S. Rasouli, M. Ghafurian, and K. Dautenhahn, “Co-Design and User Evaluation of a Robotic Mental Well-Being Coach to Support University Students’ Public Speaking Anxiety,” *ACM Trans. Comput.-Hum. Interact.*, vol. 32, no. 3, Art. 24, 2025.
 - [9] Q. Zheng et al., “EvAlignUX: Advancing UX Evaluation through LLM-Supported Metrics Exploration,” in *Proc. CHI Conf. Human Factors in Computing Systems*, 2025.
 - [10] S. Shahania, M. Spiliopoulou, and D. Broneske, “Gotta Catch ’Em All... Or Not?: How LLMs Bypass Traditional Checks & Mimic Human Response Behavior in Web Surveys,” in *Proc. Collective Intelligence Conf.*, ACM, 2025.
 - [11] J. Zhang et al., “LLM-Powered Agents for Web Interaction and Social Simulation,” ACM, 2025.
 - [12] H. Candello, M. Brachman, G. Trovato, and collaborators, “Designing Conversational Agent(ic) Systems,” in *Proc. ACM Conf. Conversational User Interfaces*, 2025.
 - [13] P. Mithun, E. Noriega-Atala, N. Merchant, and E. Skidmore, “A Gateway for Egalitarian Access to LLM Based Resources,” in *Artificial Intelligence in Education*, Springer, 2025.
 - [14] EventChat authors, “EventChat: Field Evaluation of an LLM-Driven Conversational Recommender System,” *ACM Trans. Recommender Systems*, 2025.
 - [15] H. S. Yun, M. Arjmand, P. Sherlock, M. K. Paasche-Orlow, J. W. Griffith, and T. Bickmore, “Keeping Users Engaged During Repeated Interviews by a Virtual Agent: Using Large Language Models to Reliably Diversify Questions,” in *Proc. ACM Int. Conf. Intelligent Virtual Agents*, 2024.
 - [16] P. B. Dittrich and A. Reichenbach, “Research Ethics for Data Collection from Human Participants: Case Study and Recommendations,” in *Artificial Intelligence in HCI*, Springer, 2025.
 - [17] M. Schrepp, A. Hinderks, and J. Thomaschewski, “Design and Evaluation of a Short Version of the User Experience Questionnaire (UEQ-S),” *Int. J. Interactive Multimedia and Artificial Intelligence*, vol. 4, no. 6, pp. 103–108, 2017.
 - [18] C. Bartneck, D. Kulić, E. Croft, and S. Zoghbi, “Measurement Instruments for the Anthropomorphism, Animacy, Likeability, Perceived Intelligence, and Perceived Safety of Robots,” *Int. J. Social Robotics*, vol. 1, no. 1, pp. 71–81, 2009.
 - [19] T. K. Koo and M. Y. Li, “A Guideline of Selecting and Reporting Intraclass Correlation Coefficients for Reliability Research,” *J. Chiropractic Medicine*, vol. 15, no. 2, pp. 155–163, 2016.