

UNIVERSIDAD DE COSTA RICA

ESCUELA DE CIENCIAS DE LA COMPUTACIÓN E INFORMÁTICA

PROGRAMA DE POSGRADO EN COMPUTACIÓN E INFORMÁTICA

PF-3311 AGENTES VIRTUALES INTELIGENTES

DISEÑO DEL PROTOCOLO DE EVALUACIÓN Y MATRIZ DE CONSISTENCIA

**EVALUACIÓN UX AUMENTADA CON IA PARA AGENTES VIRTUALES CORPORIZADOS:
COMPARACIÓN EXPLORATORIA ENTRE USUARIOS HUMANOS Y UN MODELO DE
LENGUAJE**

*AI-AUGMENTED UX EVALUATION FOR EMBODIED VIRTUAL AGENTS: AN EXPLORATORY COMPARISON
BETWEEN HUMAN USERS AND A LANGUAGE MODEL*

INVESTIGADOR:

DEIVERT GUILTRICHS CORDERO

PROFESOR:

ALEXANDER BARQUERO ELIZONDO

I CICLO, 2026

Tabla de contenido

Apartado A. Definición de condiciones	3
Condición experimental A: Agente virtual corporizado	3
Condición de Control B: Interfaz conversacional textual plana.....	3
Justificación de la comparación	3
Nota aclaratoria sobre el alcance del proyecto y comparaciones a generar	4
Apartado B. Matriz de consistencia metodológica	5
Apartado C. Adaptación del Protocolo del Investigador	7
Apartado D. Justificación teórica en HCI.....	7
Referencias bibliográficas	8

Apartado A. Definición de condiciones

Condición experimental A: Agente virtual corporizado

La Condición A consistirá en una interfaz web con un agente virtual corporizado representado mediante un avatar visual básico, acompañado de una ventana conversacional. El agente cumplirá el rol de asistente académico para explicar conceptos introductorios de bases de datos, como modelo entidad-relación, tablas, claves primarias, claves foráneas y relaciones entre entidades.

Técnicamente, el agente utilizará un modelo de lenguaje, denominado LLM-A, configurado mediante un prompt de sistema que limite sus respuestas al dominio académico definido. Visualmente, el agente incluirá una representación antropomórfica sencilla, con presencia en pantalla, estado activo durante la conversación y elementos visuales que indiquen que el usuario interactúa con una entidad virtual. Conductualmente, el agente deberá responder de forma clara, breve, pedagógica, amigable y controlada, evitando extenderse fuera del alcance del prototipo y redirigiendo la interacción cuando el usuario formule preguntas no relacionadas con la tarea.

Condición de Control B: Interfaz conversacional textual plana

La Condición B consistirá en una interfaz conversacional de texto plano, sin avatar, animaciones ni representación corporal del agente. Esta condición utilizará el mismo modelo de lenguaje, el mismo prompt académico base, el mismo guion de tarea y las mismas restricciones de respuesta que la Condición A. La diferencia principal será la ausencia de embodiment visual.

El participante interactuará mediante una ventana de chat convencional, similar a una interfaz de mensajería, donde podrá escribir preguntas y recibir respuestas textuales. Esta condición funcionará como baseline para comparar si la presencia visual del agente corporizado modifica la percepción de experiencia de usuario, naturalidad, confianza, credibilidad o satisfacción.

Justificación de la comparación

La comparación entre la Condición A y la Condición B permite aislar el impacto del embodiment visual del agente virtual. Al mantener constantes el modelo de lenguaje, el dominio temático, el guion de interacción, la duración de la sesión y el instrumento de evaluación, cualquier diferencia observada entre ambas condiciones puede atribuirse principalmente a la presencia o ausencia del avatar corporizado.

Esta estrategia evita comparar sistemas completamente distintos y permite evaluar de forma más controlada si la representación visual del agente mejora la percepción de naturalidad, confianza, presencia social, credibilidad o experiencia de usuario. Además, el diseño permite conservar el objetivo central del proyecto: comparar las evaluaciones UX reportadas por usuarios humanos con las evaluaciones generadas por un segundo modelo de lenguaje, LLM-B, aplicado sobre las transcripciones de interacción de ambas condiciones.

Nota aclaratoria sobre el alcance del proyecto y comparaciones a generar

Además de la comparación entre la Condición A y la Condición B, este proyecto incorpora una segunda comparación metodológica, centrada en la fuente de evaluación de la experiencia de usuario (humana o a través de inteligencia artificial).

En la comparación experimental base, la variable independiente será el tipo de interfaz del sistema: agente virtual corporizado con avatar visual básico frente a una interfaz conversacional textual plana. Esta comparación permite analizar el posible efecto del embodiment visual sobre la experiencia de usuario.

Mientras tanto, como objetivo del estudio, se compararán las evaluaciones UX reportadas por usuarios humanos con las evaluaciones generadas por un segundo modelo de lenguaje, distinto del utilizado para operar el agente conversacional.

Esta segunda comparación no constituye una condición experimental del sistema, sino una estrategia metodológica para analizar si un LLM puede funcionar como evaluador complementario de UX en fases tempranas de diseño. Por tanto, el diseño general del estudio contempla dos niveles de análisis: primero, el efecto de la condición de interfaz sobre la experiencia de usuario; segundo, el grado de concordancia entre la evaluación humana y la evaluación generada por IA sobre las interacciones registradas.

En síntesis:

Nivel de comparación	¿Qué se compara?	Propósito
Comparación experimental	Condición A: agente corporizado vs. Condición B: chat textual plano	Analizar el impacto del embodiment visual en la experiencia de usuario.
Comparación metodológica	Evaluación humana vs. evaluación generada por LLM-B	Analizar si un LLM puede funcionar como evaluador complementario de UX.

Esta aclaración evita confundir las condiciones experimentales del sistema con las fuentes de evaluación. Las condiciones A y B corresponden al diseño del prototipo; la comparación humano-IA corresponde al análisis posterior de los resultados.

Apartado B. Matriz de consistencia metodológica

Pregunta de investigación	Variable o constructo	Instrumento validado	Tarea asociada
RQ1. ¿Qué grado de concordancia existe entre las puntuaciones de experiencia de usuario reportadas por usuarios humanos y las puntuaciones generadas por un modelo de lenguaje evaluador, al aplicar el mismo instrumento UX sobre una interacción con un agente virtual corporizado académico?	Concordancia general entre evaluación humana y evaluación generada por LLM-B. Experiencia de usuario percibida, usabilidad, claridad, utilidad percibida, satisfacción, confianza, credibilidad y naturalidad.	UEQ-S [1] como instrumento principal de experiencia de usuario. Godspeed [2] en dimensiones seleccionadas para evaluar antropomorfismo, simpatía, inteligencia percibida y seguridad percibida.	El participante interactúa con el agente para solicitar una explicación sobre diseño de bases de datos, pedir un ejemplo cotidiano y confirmar su comprensión. Luego completa UEQ-S. La transcripción se entrega a LLM-B para completar el mismo instrumento.
RQ2. ¿En qué medida las puntuaciones generadas por el modelo de lenguaje evaluador concuerdan con las puntuaciones reportadas por usuarios humanos, considerando como referencia exploratoria mínima un ICC ≥ 0.70 y contrastando si se aproximan o superan el umbral de ICC ≥ 0.75 asociado con buena confiabilidad?	Nivel cuantitativo de concordancia entre fuentes de evaluación. Confiabilidad interevaluador entre usuarios humanos y LLM-B.	UEQ-S como fuente de puntuaciones comparables. ICC [3] como métrica estadística de análisis, no como instrumento validado. Estadística descriptiva de medias, desviaciones y diferencias por dimensión UX.	Se comparan las puntuaciones humanas y las puntuaciones de LLM-B para cada sesión registrada. Se calcula ICC para determinar si existe concordancia exploratoria aceptable.
RQ3. ¿Qué limitaciones, riesgos y consideraciones deben tomarse en cuenta al incorporar un modelo de lenguaje como evaluador	Riesgo de circularidad, sesgos del LLM, limitaciones de evaluación textual, pérdida de variables multimodales,	Análisis cualitativo de observaciones abiertas, notas del investigador y comparación crítica entre	Se revisan las diferencias entre respuestas humanas y del LLM-B, especialmente cuando el modelo evalúa aspectos que no pudo

complementario de UX en agentes virtuales corporizados?	sobreinterpretación de respuestas generadas.	evaluaciones humanas y evaluación del LLM-B.	observar directamente, como gestos, voz, expresiones o presencia corporal.
---	--	--	--

Nota: La RQ2 y RQ3 fueron modificadas según retroalimentación del profesor en la calificación del entregable # 1.

Apartado C. Adaptación del Protocolo del Investigador

El protocolo oficial del experimento fue adaptado en formato HTML a partir de la guía base proporcionada para la actividad. El archivo personalizado incluye la identificación formal del estudio, consentimiento informado, generación de ID anónimo de participante, asignación aleatoria a Grupo A o Grupo B, instrucciones neutras de interacción, listado de cuestionarios post-interacción y plan de anonimización y resguardo de logs.

Archivo HTML en GitHub:

https://github.com/deivert-guiltrichs/ai-ux-embodied-agent-evaluation/blob/main/docs/Guia_Procedimiento_PF3311_Deivert.html

Apartado D. Justificación teórica en HCI

El diseño experimental se fundamenta en teorías clásicas y actuales de HCI sobre agentes virtuales, embodiment, interacción social con sistemas computacionales y percepción del usuario.

En primer lugar, la Condición A incorpora un agente visualmente corporizado porque la literatura sobre Embodied Conversational Agents, especialmente el trabajo de Justine Cassell [4], plantea que los agentes conversacionales corporizados no se limitan al lenguaje verbal, sino que integran señales no verbales como presencia visual, gestos, expresiones, orientación corporal y comportamiento comunicativo. Aunque el prototipo de este curso no implementará una simulación corporal avanzada, la presencia visual del avatar permite evaluar si una representación básica del agente modifica la percepción de naturalidad, presencia social y experiencia de usuario frente a una interfaz textual plana.

En segundo lugar, el diseño toma como referencia de forma limitada la línea de Timothy Bickmore sobre agentes relacionales [5]. Esta perspectiva resulta útil para justificar decisiones de tono, consistencia comunicativa y percepción de apoyo. No obstante, el agente propuesto no pretende construir una relación afectiva profunda ni de largo plazo, sino ofrecer una interacción académica breve, clara y respetuosa.

En tercer lugar, se considera el Efecto Proteus, asociado con Nick Yee y Jeremy Bailenson, según el cual la apariencia de un avatar o representación virtual puede influir en el comportamiento, actitudes o percepciones de los usuarios dentro de entornos digitales [6]. En este estudio, dicho efecto se toma como advertencia metodológica: la presencia de un avatar puede modificar la forma en que el participante interpreta la interacción, incluso cuando el contenido textual sea equivalente al de la condición de control. Por ello, la comparación entre Condición A y Condición B resulta necesaria para aislar el impacto de la representación visual del agente.

Adicionalmente, el diseño considera la perspectiva de Nass y Reeves sobre la tendencia de las personas a responder socialmente ante computadoras y sistemas interactivos cuando estos presentan señales comunicativas o sociales [7]. En el contexto de este proyecto, el agente será

diseñado con un tono claro, pedagógico, breve y amigable, de manera que el usuario pueda percibirlo como una entidad de apoyo académico. Esta decisión respalda la medición de constructos como confianza, credibilidad, satisfacción y naturalidad percibida.

Por otro lado, el uso de dos modelos de lenguaje distintos responde a una decisión de control metodológico. El LLM-A será utilizado para operar el agente conversacional, mientras que el LLM-B será utilizado para evaluar la transcripción de la interacción. Esta separación evita que el mismo modelo genere y evalúe sus propios patrones de respuesta, reduciendo el riesgo de circularidad.

Finalmente, el estudio reconoce explícitamente que una evaluación basada en transcripción textual no puede medir de manera directa elementos multimodales como tono de voz, gestos, expresiones faciales, movimiento ocular o fluidez de animación. Por ello, los resultados del LLM-B serán interpretados como una evaluación complementaria de la interacción documentada, no como sustituto de la experiencia humana ni como evaluación completa del embodiment.

Referencias bibliográficas

- [1] M. Schrepp, A. Hinderks, and J. Thomaschewski, “Design and Evaluation of a Short Version of the User Experience Questionnaire (UEQ-S),” *International Journal of Interactive Multimedia and Artificial Intelligence*, vol. 4, no. 6, pp. 103–108, 2017.
- [2] C. Bartneck, D. Kulić, E. Croft, and S. Zoghbi, “Measurement Instruments for the Anthropomorphism, Animacy, Likeability, Perceived Intelligence, and Perceived Safety of Robots,” *International Journal of Social Robotics*, vol. 1, no. 1, pp. 71–81, 2009.
- [3] T. K. Koo and M. Y. Li, “A Guideline of Selecting and Reporting Intraclass Correlation Coefficients for Reliability Research,” *Journal of Chiropractic Medicine*, vol. 15, no. 2, pp. 155–163, 2016.
- [4] J. Cassell, J. Sullivan, S. Prevost, and E. Churchill, Eds., *Embodied Conversational Agents*. Cambridge, MA, USA: MIT Press, 2000.
- [5] T. W. Bickmore and R. W. Picard, “Establishing and Maintaining Long-Term Human-Computer Relationships,” *ACM Transactions on Computer-Human Interaction*, vol. 12, no. 2, pp. 293–327, 2005.
- [6] N. Yee and J. Bailenson, “The Proteus Effect: The Effect of Transformed Self-Representation on Behavior,” *Human Communication Research*, vol. 33, no. 3, pp. 271–290, 2007.
- [7] B. Reeves and C. Nass, *The Media Equation: How People Treat Computers, Television, and New Media Like Real People and Places*. Cambridge, UK: Cambridge University Press, 1996.